

多智能体系统中的任务分解

——基于加州大学伯克利分校 Long Lian 博士论文摘要、第一章与第二章译文

译者：MiniMax 翻译助手

2026 年 9 月

目录

1	引言	5
1.1	研究动机	5
1.2	研究贡献概述	6
1.3	论文组织结构	8
2	LLM 锚定的扩散模型：用大语言模型增强文生图扩散模型的提示词理解能力	9
2.1	引言	9
2.2	相关工作	10
2.3	LLM 锚定的扩散模型	12
2.3.1	LLM 布局生成	12
2.3.2	布局锚定的 Stable Diffusion	13
2.3.3	LMD 的额外能力	15
2.4	评测	16
2.4.1	定性比较	16
2.4.2	定量评估	17
2.4.3	消融实验	18
2.4.4	基于评估者的主观评估	19

2.5	讨论	19
2.6	小结	20
3	LLM 锚定的视频扩散模型	21
3.1	引言	21
3.2	相关工作	22
3.3	大语言模型能生成时空动力学吗?	23
3.4	DSL 锚定的视频生成	25
3.5	评测	26
3.5.1	实验设置	26
3.5.2	生成 DSL 的评测	27
3.5.3	生成视频的评测	28
3.6	讨论与未来工作	30
4	自纠正的 LLM 控制扩散模型	31
4.1	引言	31
4.2	相关工作	32
4.3	自纠正的 LLM 控制扩散模型	33
4.3.1	LLM 驱动的物体检测	33
4.3.2	LLM 控制的分析与修正	34
4.3.3	无需训练的图像修正潜空间操作	34
4.3.4	自纠正过程的终止	35
4.3.5	统一的文生图生成与图像编辑	36
4.4	实验	36
4.4.1	与图像生成方法的对比	36
4.4.2	图像编辑应用	37
4.4.3	多轮自纠正	37
4.5	讨论	38
4.6	小结	38
5	Describe Anything: 精细的局部图像与视频字幕生成	39
5.1	引言	39

5.2	相关工作	41
5.3	Describe Anything Model (DAM)	42
5.3.1	任务形式化	42
5.3.2	模型架构	43
5.3.3	焦点提示词	43
5.3.4	局部化视觉骨干网络	44
5.3.5	生成详细的局部描述	45
5.3.6	扩展到视频	45
5.4	DLC-SDP: 基于 SSL 的数据流水线	45
5.4.1	阶段一: 利用已有标注	45
5.4.2	阶段二: 使用未标注数据的 SSL	46
5.5	DLC-Bench: DLC 的基准	46
5.6	实验结果	47
5.6.1	定量结果	47
5.6.2	定性结果	48
5.6.3	消融研究	49
5.7	讨论与小结	49
6	语言引导的视觉分解在当下仍具意义	50
6.1	为什么显式的视觉结构仍然重要	50
6.2	LMD、LVD 与 SLD 的持续价值	51
6.3	Describe Anything 为何仍然有用	51
6.4	第一部分回顾	52

摘要

论文题目：多智能体系统中的任务分解

作者：Long Lian（练龙）

加州大学伯克利分校电子工程与计算机科学系

导师：Trevor Darrell 教授

近年来，以”基础大模型”(Foundation Models) 为代表的人工智能技术在语言、视觉和推理领域取得了飞速进展。如今，单一模型就能完成代码编写、问答交流、文生图、视觉场景描述乃至数学解题等任务。然而，许多真实场景下的任务依然棘手——原因不在于模型本身不够强大，而在于这些任务远不止”输入到输出”的一一映射那么简单。它们要求模型能够拆解模糊的目标、协调多个专业化的子系统、把中间表示扎根到真实的视觉世界中，并自适应地在子任务间分配算力。

本论文围绕”多智能体系统中的任务分解”这一核心思想展开研究，探讨如何借助任务分解让生成式模型和推理模型变得更可控、更具扩展性、更加高效。为回答这一核心问题，本文从两个相互补充的角度展开：

- **视觉生成方向**。本文展示了如何让大语言模型（LLM）充当视觉生成的”规划器”和”控制器”：把复杂的文本提示翻译成结构化的空间与时间表征，借助反馈机制修正生成错误，从而实现对图像和视频更精细的控制。此外，本文还提出了 **Describe Anything**（万物皆可描述）模型，能够为图像或视频中的指定区域生成详尽的局部描述，这一能力同时也为可控的图像与视频合成提供了高质量的合成数据。
- **语言模型推理方向**。本文把”任务分解”的思路延伸到语言模型推理中，提出了自适应并行推理系统以及高效的”多线程”推理方法。

纵观上述所有贡献，可以发现一条贯穿始终的主线：当复杂任务被拆解为彼此交互的子问题时，模型就能借助语言、视觉锚定（visual grounding）和并行计算，去攻克那些”单体生成”难以解决的问题。综合来看，本论文倡导一种新的 AI 系统观：未来的智能系统不再是一块铁板一块的整体，而应是一群彼此协作的智能体和模块的集合——它们各司其职、各有专长，能够规划、验证、专精、并行推理。

关键词：任务分解、多智能体系统、大语言模型、可控视觉生成、并行推理、自适应计算

1 引言

1.1 研究动机

现代基础模型彻底改变了计算机处理语言、图像、视频以及长链路推理的方式。一个模型就能写代码、做问答、根据文字生成图像、描述画面、做数学题，看似无所不能。然而，许多真正落地的任务，对单一的”端到端生成”来说依然困难重重。

为什么会这样？我们可以观察三类典型场景：

1. **复杂提示词的挑战。**一段看似简单的提示词，往往同时包含多个物体、多种关系、若干约束条件，以及跨越时间的事件。例如”三只穿着红色毛衣的熊猫在雪地里向左走，但最右边那只不要戴帽子”——这种句子一旦丢给文生图模型，几乎注定要翻车。
2. **视觉理解的尴尬。**当我们希望模型描述图像中某个特定区域时，往往需要在”放大切片、看清细节”与”保留全图上下文”之间走钢丝。单纯把区域裁出来单独看，模型会丢失全局信息；不裁切，又看不清细节。
3. **推理任务的瓶颈。**很多困难推理题天然可以被拆成若干**独立可并行**的子问题。然而，主流的大模型推理范式（比如”思维链”Chain-of-Thought）只能**串行地**一步步推，浪费了大量本可以并行利用的计算资源。

问题的根源并不只是模型容量不足，更在于”任务本身的结构”——任务是如何被表征、如何被执行的。换言之，模型越强并不一定意味着越聪明，关键在于我们怎么把任务”组织”好，让模型能发挥最大效力。

本论文的核心主张：用”多智能体系统中的任务分解”这一范式来突破上述瓶颈。这里的核心思想其实很朴素——当复杂任务被拆解成若干彼此交互的子问题，且每个子问题都有明确的中间表征时，整个任务就变得可控、可扩展、可协作。具体来说：

- 一个语言模型可以把一段文字提示翻译成**空间布局**（spatial layout）；
- 一个生成模型可以把这个布局**锚定**到视觉合成上；
- 一个验证器或控制器可以**检测失败**，并提出修改方案；
- 一个描述模型可以把**局部证据**与**全局上下文**结合起来；

- 一个推理系统可以分叉成多个并行线程，最后合并结果。

这些系统在广义上都是”多智能体”的：它们协调不同的角色、模块、调用或推理线程，每个部分各司其职，共同完成整个计算任务。

为什么是大语言模型（LLM）让这种分解变得格外强大？因为大模型经过广泛的语言和过程性知识训练后，可以直接充当规划器、解析器、控制器、标注员、推理智能体等多种角色，而无需对每一种新分解方式都做有监督训练。但是，光有语言还不够——这些分解必须扎根到视觉表征中，必须与可控的生成模型对接，并且最终要落到实际提升精度或效率的算法上。因此，本论文要回答的核心问题是：如何在视觉生成、视觉数据生成和推理这三大领域中，把”以语言为媒介的任务分解”做实、做深？

1.2 研究贡献概述

本论文围绕”多智能体系统中的任务分解”这一主题，系统地给出了六项研究成果。下面逐一简要介绍。

第 2 章——LLM-grounded Diffusion（基于 LLM 锚定的扩散模型） 本方法是一种无需训练的文生图提示词增强方法。它把图像生成拆成两阶段：第一阶段，由一个大语言模型（LLM）将复杂提示词解析为结构化的布局——包含物体、边界框、背景描述和反向提示词；第二阶段，一个由布局驱动的扩散控制器依据这个布局来引导图像合成。这种分解让系统能更可靠地处理涉及计数（几件物品）、否定（不要出现什么）、属性绑定（哪个物体有哪个特征）、空间关系（左右、上下）的提示词，比直接文生图稳定得多。

第 3 章——LLM-grounded Video Diffusion（基于 LLM 锚定的视频扩散模型） 本章把”以语言引导的分解”从图像延伸到视频。LLM-grounded Video Diffusion 让 LLM 生成动态场景布局（即物体及其边界框随时间如何变化），然后用这些布局来引导文生视频扩散。这把时空约束变得显式化，让系统能更好地遵循涉及运动、物体交互、时序事件的提示词。本章证明：即便 LLM 不是专门作为视频生成器训练的，也能给出有用的时空结构。

第 4 章——Self-correcting LLM-controlled Diffusion（自纠正的 LLM 控制扩散） 本章把”任务分解”看作一个迭代修正的过程。Self-correcting LLM-controlled Diffusion 利用外部感知模块和 LLM 控制来分析已生成的图像、识别与提示词的偏差，并提出在潜空间（latent space）中的修正操作。系统把生成拆成生成、检测、诊断、修复四步，

而不是依赖”一次生成就走天下”。这使得图像在物体数量、属性或空间关系上出错时，能够实现无需训练的自动纠错。

第 5 章——Describe Anything（万物皆可描述）本章提出了 Describe Anything 模型——一种针对图像或视频中用户指定区域的精细局部描述系统。尽管该方法本身是一种视觉-语言模型，但它被归入本论文的”视觉生成”部分，原因在于：高质量的局部描述可以为 LLM-grounded Diffusion、LLM-grounded Video Diffusion 等系统提供合成监督数据。该方法把视觉证据拆成局部聚焦区域与全局上下文，再通过一个局部化的视觉骨干网络（vision backbone）将二者融合。这一设计既保留了区域的细粒度细节，又避免了单纯裁剪导致的上下文丢失。除了用于可控的图像视频合成的数据生成外，这一能力还可以服务于诸如视障人士辅助等无障碍应用。本章还提出了 **DLC-Bench** 基准，用于评估”精细局部描述”任务，避免依赖不完整的参考描述。

第 6 章——关于”语言引导的视觉分解”的意义讨论本章反思了第一部分所提出的视觉分解方法的持续价值。作者认为：尽管现代的图像和视频生成器已经变得相当强大，但显式的空间、时间、局部描述结构在那些对”正确性、可控性、可检查性、数据生成”有要求的提示词和工作流中，依然不可或缺——它们不仅仅是为了”看起来像样的视觉合成”。本章同时讨论了为何精细局部描述仍是一项有独立价值的任务，以及为何它依然是可控视觉生成的重要合成监督源。

第 7 章——Adaptive Parallel Reasoning（自适应并行推理）本章把”分解”思路引入到大语言模型的推理过程中。Adaptive Parallel Reasoning 训练模型使用显式的”分叉（spawn）”与”合并（join）”操作，让一个解题过程可以分支成多个并行的子搜索，再把结果汇总起来。本章证明：通过把算力分配到多条并行推理路径上，可以在精度-时延权衡上明显优于单一串行轨迹——前提是题目本身允许这种有用的分解。

第 8 章——ThreadWeaver（”织线者”）本章开发了 ThreadWeaver 框架，证明”自适应并行推理”能够与强推理语言模型协同工作。ThreadWeaver 在第 7 章的”分叉-合并”分解基础上，进一步训练现有的串行推理 LLM，使其能够动态决定何时分叉出并发线程、何时合并结果。本章表明：这种并行推理可以在精度上追平同等水平的串行思考模型，同时显著降低关键路径上的 token 时延——这意味着”任务分解”不仅是一种算法搜索策略，更是一条通向更快推理推理的实用路径。

1.3 论文组织结构

本论文剩余部分的结构安排如下：

- 第一部分（语言引导的视觉生成，第 2 至 6 章）介绍那些用 LLM 分解和控制图像/视频合成的方法、一个能为下游数据生成服务的局部描述模型，以及一个关于这些思想持续价值的综合性章节。
- 第二部分（自适应并行推理，第 7 至 8 章）介绍那些把语言模型推理拆解为并发推理线程的方法。
- 第 9 章（结论与未来工作）总结研究发现，并展望未来研究方向。

2 LLM 锚定的扩散模型：用大语言模型增强文生图扩散模型的提示词理解能力

本章基于以下已发表论文：

Long Lian, Boyi Li, Adam Yala, Trevor Darrell. “LLM-grounded Diffusion: Enhancing Prompt Understanding of Text-to-Image Diffusion Models with Large Language Models.” *Transactions on Machine Learning Research (TMLR)*, 2024.

2.1 引言

近年来，文生图（text-to-image）领域取得了显著进展，尤其是**扩散模型**（Diffusion Models）的崛起。这些模型在根据文本提示生成逼真且多样的图像方面展现了惊人的能力。然而，尽管视觉效果令人印象深刻，扩散模型在**准确理解复杂提示词**方面常常力不从心。**图 2.1** 显示，即使是当前最强的 Stable Diffusion 甚至最新的 SDXL，也常常无法正确生成**指定数量的物体**、难以理解提示词中的**否定语义**，并且在**空间推理与属性绑定**（attribute binding）方面频频出错。

一种显而易见的解决方案是：收集一个包含复杂描述的多模态数据集，并重新训练一个文生图扩散模型以增强其提示词理解能力。然而，这种方案有明显缺陷：构建多样化、高质量的多模态数据集需要消耗大量时间与资源，更不用说在如此庞大的数据上训练或微调一个扩散模型本身的难度了。

与之相反，本文提出了一种**全新、无需训练**（training-free）的方法——用一个大语言模型（LLM）来为扩散模型提供**锚定**（grounding），从而增强其提示词理解能力。我们的方法 **LLM-grounded Diffusion**（简称 **LMD**）由一个**两阶段生成过程**组成，如图 2.2 所示。

阶段一：我们通过**上下文学习**（in-context learning）将一个大语言模型改造成一个**文本-布局生成器**。给定一段描述目标图像的提示词，LLM 会生成一个**带描述的边界框**（captioned bounding boxes）形式呈现的场景布局，同时附带一个**背景描述**和用于避免生成某些内容的**反向提示词**（negative prompt）。

阶段二：我们引入一种**全新的控制器**，它能够引导那些**没有针对布局进行训练的现成扩散模型**（例如 Stable Diffusion）按照阶段一生成的布局来合成图像。与此前提出的、并行同期的几项区域控制工作（如 Multidiffusion、Training-free layout control with cross-

attention guidance、Boxdiff) 相比, 那些方法只能对语义层面的空间区域施加控制, 而我们的方法能够对指定区域内的具体物体实例进行精确控制。

值得强调的是, 两个阶段都使用了冻结的、预训练好的现成模型, 这意味着我们的方法可以无缝接入任何独立训练的 LLM 或扩散模型, 无需任何参数优化。

除了提示词理解能力的提升外, 我们的方法还能自然而然地支持: (1) 多轮对话式的指令化场景描述 (参见图 2.3); (2) 用基础扩散模型原本不支持的语言生成图像 (参见图 A.6)。两者均无需额外训练。

如图 2.1 所示, LMD 一次性统一解决了提示词理解中的多个常见缺陷, 并能基于复杂提示词生成准确且高质量的图像。我们证明: 使用 LLM 生成的布局进行锚定的扩散模型, 显著优于其基础扩散模型, 并在多项近期基线之上, 将四项任务上的平均生成准确率提升了一倍。

本文的主要贡献包括:

1. 提出一种无需训练的两阶段生成流水线, 通过引入大语言模型来增强文生图扩散模型的提示词理解能力。
2. 提出了布局锚定的 Stable Diffusion——一种全新的控制器, 能够引导现成的扩散模型基于 LLM 给出的实例级边界框布局生成图像。
3. LMD 能够实现基于指令的多轮场景描述, 并扩展了提示词的语言覆盖范围。
4. 提出了一套基准测试用于评估文生图模型的提示词理解能力, 并展示了 LMD 在与近期基线的对比中的优越性能。

我们期待 LMD 能让用户对文生图扩散模型拥有更精细的控制力。本文的代码、演示与基准测试均已开源。

2.2 相关工作

文生图扩散模型。近年来, 利用扩散模型从文本描述生成高质量图像已变得流行。尽管视觉效果令人惊艳, 这些模型在面对涉及属性绑定与空间推理等技能的复杂提示词时, 仍然常常表现不佳。

用于视觉锚定的大语言模型。许多多模态模型受益于将 LLM 整合进来以锚定视觉模型。例如 BLIP-2 通过冻结的图像编码器与 LLM 自举了视觉-语言预训练; Flamingo 处理

小样本视觉问答与字幕任务；LayoutTransformer 使用 Transformer 来预测布局，但聚焦于在封闭物体类别集合上生成布局，因此无法为训练集之外的物体生成布局；Visual ChatGPT 和 GILL 也在条件图像生成中使用了 LLM。然而，这些方法仍然依赖 CLIP 文本嵌入来向扩散模型传递信息。因此，与本文方法相比，它们常常表现出**控制力不足**——因为我们明确要求 LLM 推理物体之间的空间组成，并施加**直接的空间控制**。与此工作并行的 LayoutGPT 提出用 LLM 以 CSS 结构生成布局。但 LayoutGPT 依赖一个标注了框与字幕的数据集来为 LLM 检索相关的上下文示例，而我们的方法证明：**高质量布局生成的能力已经蕴含在预训练 LLM 的权重中**，可以使用一组固定的上下文示例加以激发，无需任何外部标注。

空间条件图像生成方法。这类方法依据给定的先验（如姿态、分割图、笔画、布局）生成图像。在扩散模型流行之前，SPADE、BlobGAN 和 Layout2Im 已能基于给定布局合成逼真图像。基于场景图的方法也可生成图像。ControlNet、SpaText、LayoutDiffuse、LayoutDiffusion、GLIGEN 和 ReCo 提出了**基于训练的**扩散模型空间条件生成方法，其中 GLIGEN 和 ReCo 支持布局框的**开放词汇标签**。然而，这些方法依赖带标注的外部数据集（如 COCO）来提供带框和字幕的图像。而且，基于训练的方法与 LoRA 权重等附加模块不兼容，导致难以在无框标注的训练集上训练新的 LoRA 模型。相比之下，我们提出了一种**无需训练的**生成控制器，能够引导那些**并非专门针对布局锚定训练的**现成文生图扩散模型，且**不需要任何外部数据集**。此外，我们的方法还可以与基于训练的方法结合，进一步提升效果。

最近，Multidiffusion、Training-free layout control with cross-attention guidance 和 Boxdiff 实现了训练自由的区域控制，与我们布局到图像的阶段有相似的任务设定。然而，这些工作将图像生成锚定在**语义层面**，对每个语义区域内物体实例的**数量**几乎无法控制；与此对照，本文方法专注于**实例级别的**锚定。

与我们基于指令的场景描述相似的工作，InstructPix2Pix 提出了基于指令的图像编辑。Visual ChatGPT 和 Visual Programming 也允许在 LLM 驱动的对话中使用外部图像编辑模型。与这些方法不同，**我们的目标是编辑场景布局而非图像像素**，因此可以轻松支持更广泛的指令，如**交换/移动物体**等。

2.3 LLM 锚定的扩散模型

在本节中，我们将正式介绍本文方法 LLM-grounded Diffusion (LMD)。LMD 聚焦于文生图任务：在给定文本提示 y 的情况下生成图像 x_0 。我们的方法分两阶段生成图像：(1) 文本-布局生成；(2) 布局锚定的图像生成。布局到图像阶段建立在潜在扩散框架 (Latent Diffusion) 之上，相关预备知识请参见附录 A.1。

2.3.1 LLM 布局生成

布局表示。LMD 的布局表示包含两个组成部分：(1) 每个前景物体的带描述边界框（采用 $(x, y, \text{宽}, \text{高})$ 的坐标格式）；(2) 一段简洁的背景描述，以及一个可选项反向提示词，用于指明生成图像中不应出现的内容。当布局对”不应出现什么”没有限制时，反向提示词为空字符串。

指令。我们发给 LLM 的文本指令由两部分组成：

1. 任务说明：

“你的任务是为提示词中提到的物体生成边界框，并附带一段描述场景的背景提示词。”

2. 支持细节：

“图像尺寸为 512×512 ……每个边界框应当采用……格式。如有需要，你可以做出合理的推测。”

上下文学习。与 InstructPix2Pix 类似，我们在任务说明之后为 LLM 提供了人工策划的示例。通过这些示例，我们明确布局的表示格式，并提供化解歧义的偏好。一个示例如下：

描述：一幅水彩画，画的是客厅里一张木桌，桌上放着一个苹果

物体：[(“一张木桌”, [65, 243, 344, 206]), (“一个苹果”, [206, 306, 81, 69])]

背景提示词：一幅水彩画，画的是客厅

反向提示词：(空)

为了实现精确的布局控制，我们在示例设计上严格遵守两个关键原则：（1）每个物体实例对应一个单独的边界框。例如，如果提示词提到四个苹果，我们就在每个框里都写上“一个苹果”，共四个框。（2）不要把任何前景物体遗漏到背景描述中，以确保所有前景物体都受我们的布局锚定图像生成器控制。这两个原则确保了**精确、实例可控**的布局生成。

LLM 完成输出。在提供了上下文示例之后，我们查询 LLM 完成输出：

描述： [来自用户的输入提示词]

物体： [LLM 完成输出的开始]

从 LLM 完成输出中解析得到的布局随后被用于后续的图像生成过程。完整的提示词请参见附录 A.11。

2.3.2 布局锚定的 Stable Diffusion

在这一阶段，我们引入一种控制器，将图像生成**锚定**在 LLM 生成的布局上。之前的训练自由区域控制方法通过**区域去噪**或**注意力操控**施加语义引导，但这些方法**缺乏在某个语义区域内控制物体数量的能力**。这种局限源于不同的实例在潜在空间或注意力图中往往无法区分，从而难以实现实例级别的控制。

相比之下，LMD 通过为每个单独的边界框生成掩码化的潜在表示，再把这些掩码化的潜在表示组合为最终图像生成的先验，实现了**实例级别的锚定**。这让我们能为每个物体实例实现**精确定位与属性绑定**。

逐框掩码化的潜在表示。虽然扩散模型在其潜在空间或注意力图中本身缺乏实例级别的区分能力，难以做精细控制，但我们注意到：它们通常能够针对**单个指定实例**生成图像。因此，我们**逐个前景框**进行处理，以实现实例级锚定。

如图 2.5(a) 所示，对于每个前景物体 i ，我们首先通过从 z_T 到 $z_0^{(i)}$ 的去噪过程生成一个仅含单个实例的图像，其中 $z_t^{(i)}$ 表示物体 i 在去噪时间步 t 的潜在表示。在该去噪过程中，我们使用 “[背景提示词] + with + [边界框描述]”（例如 “a realistic image of an indoor scene with a gray cat”）作为去噪的文本提示。所有框共享初始噪声潜在表示 z_T ，以保证全局一致的视角、风格与光照（即 $\forall i, z_T^{(i)} = z_T$ ）。

为了确保物体与边界框对齐，我们操控噪声预测网络的**交叉注意力图** $A^{(i)}$ 。每张注意力

图刻画了像素到文本标记的关联强度：

$$A_{uv}^{(i)} = \text{Softmax}(q_u k_v^\top) \quad (1)$$

其中 q_u 与 k_v 分别是图像在空间位置 u 的线性变换特征和提示词中第 v 个文本标记的特征。

参照相关文献的做法，我们增强框内像素到对应框描述标记的交叉注意力，同时抑制框外像素对它们的注意力。为此，我们定义如下简洁的能量函数：

$$E(A^{(i)}, i, v) = -\text{TopK}_u(A_{uv}^{(i)} \cdot b^{(i)}) + \omega \cdot \text{TopK}_u(A_{uv}^{(i)} \cdot (1 - b^{(i)})) \quad (2)$$

其中 $\cdot$ 表示逐元素乘积， $b^{(i)}$ 是框 i 的矩形二值掩码（框内为 1）， TopK_u 沿空间维度 u 取 top-k 平均值， $\omega = 4.0$ 。该能量函数在每次去噪步前通过更新潜在表示来最小化：

$$z_t^{(i)} \leftarrow z_t^{(i)} - \eta \nabla_{z_t^{(i)}} \sum_{v \in V_i} E(A^{(i)}, i, v) \quad (3)$$

$$z_{t-1}^{(i)} \leftarrow \text{Denoise}(z_t^{(i)}) \quad (4)$$

其中 η 为引导强度，集合 V_i 包含框 i 在提示词中的描述标记索引（例如为框 i 生成掩码化潜在表示时，提示词为 “[背景提示词] with a gray cat”， V_i 即对应 “a gray cat” 的标记索引）。 $\text{Denoise}(\cdot)$ 是潜在扩散框架中的一次去噪步。

生成结束后，我们获得与框描述相对应的交叉注意力图，并将其作为该物体的显著性掩码。我们可以可选地使用 SAM 来进一步精修掩码质量——既可以用显著性最高的像素位置查询，也可以直接用布局框查询。SAM 的功能也可以由简单的阈值化替代（小节 2.4 实验中有所尝试）。得到恰好覆盖一个前景实例的精修掩码 $m^{(i)}$ 后，我们在每个去噪步对其与潜在表示做逐元素乘积，生成一系列掩码化的实例潜在表示 $\{\hat{z}_t^{(i)}\}_{t=0}^T$ ：

$$\hat{z}_t^{(i)} = z_t^{(i)} \otimes m^{(i)} \quad (5)$$

作为实例级控制先验的掩码化潜在表示。这些掩码化的实例潜在表示随后被用作实例级提示，引导扩散模型生成整体图像。如图 2.5(b) 所示，在整体去噪过程早期的每个时间

步，我们将各掩码化前景潜在表示 $\hat{z}_t^{(i)}$ 拼装到组合潜在表示 $z_t^{(\text{comp})}$ 上：

$$z_t^{(\text{comp})} \leftarrow \text{LatentCompose}(z_t^{(\text{comp})}, \{\hat{z}_t^{(i)}, m^{(i)}\}), \quad \forall i \quad (6)$$

其中 $z_T^{(\text{comp})}$ 由 z_T 初始化以保持前景一致性。算子 LatentCompose 只是简单地将掩码化前景潜在表示 $\hat{z}_t^{(i)}$ 拼到 $z_t^{(\text{comp})}$ 的对应位置上。

由于扩散模型倾向于在初始去噪步确定物体布局，在后续步生成细节，我们仅在时间步 T 到 rT ($r \in [0, 1]$ ，平衡实例控制与图像一致性) 期间执行上述拼装。通过主要干预物体布局阶段，我们的方法仅提供实例级布局提示，而不会强制每个掩码区域的最终生成结果都与逐框生成时完全一致。

为了使引导更稳健，我们进一步将逐框生成的交叉注意力图迁移到组合生成中的对应区域，调整后的能量函数为：

$$E^{(\text{comp})}(A^{(\text{comp})}, A^{(i)}, i, v) = E(A^{(\text{comp})}, i, v) + \lambda \sum_{u \in V'_i} |A_{uv}^{(\text{comp})} - A_{uv}^{(i)}| \quad (7)$$

其中 $\lambda = 2.0$ ，每个框 i 的能量值累加用于优化。 V'_i 表示整体去噪过程提示词中对应框描述的标记索引，定义与公式 (2.3) 中的 V_i 类似。

通过这种方式，我们的控制器引导扩散模型在每个掩码化位置上生成一个实例，同时最终生成结果在前景-背景的组合上保持自然连贯。最终，我们通过扩散图像解码器将潜在表示 $z_0^{(\text{comp})}$ 解码为像素 x_0 。

与基于训练的方法集成。我们这种训练自由的控制器也可以与基于训练的方法（如 GLIGEN）结合使用，以利用实例标注的外部数据集。由于 GLIGEN 训练了接收框输入的适配器层，与 GLIGEN 的集成（记作 **LMD+**）就是采用其适配器权重并将布局引导传递给适配器层。需要注意的是，LMD+ 同时使用了上述适配器以及实例级引导，这大大超过了仅使用 GLIGEN 适配器的情况（如表 2.2 所示）。通过这种集成，我们在不进行额外训练的情况下实现了更强的实例和属性控制。

2.3.3 LMD 的额外能力

我们的 LLM 锚定生成流水线还具备两个无需额外训练即可获得的能力：

(1) **基于指令的多轮场景描述。**借助支持多轮对话的 LLM（如 GPT-3.5/4），LMD 让用

户可以在初始提示词之后通过**多条后续指令**来描述目标图像（参见图 2.3）。具体来说，在完成初始图像生成后，用户可以简单地给 LLM 一些**澄清或追加需求**。借助 LLM 更新的布局，我们可以再次调用 LMD 按照更新后的布局生成图像。**更新布局而非原始图像**为 LMD 带来了若干优势（参见图 2.6）：

- 经过多轮请求后，生成结果能**保持一致性**，而不会逐步偏离初始图像；
- LMD 能处理涉及**空间推理**的请求——这正是前代基于指令的图像编辑方法 InstructPix2Pix 的局限。相比之下，我们实验验证了 Visual ChatGPT（用 ChatGPT 加上 InstructPix2Pix 等工具）**无法遵循图 2.6 中的指令**，尤其是多轮对话中的空间指令。

此能力对 LMD 和 LMD+ 均适用。我们的 LMD 能处理开放式场景调整、为当前场景提供建议、理解对话中的用户请求，并允许用户在保留整体风格与布局的前提下尝试不同的细节调整，从而促进**细粒度的内容创作**。

(2) 支持更多语言。通过给出一个非英语用户提示词配英语布局输出的示例，LLM 布局生成器可以接受非英语的用户提示词，并输出带英语描述的布局。这使得我们能够在无需额外训练的情况下，用基础扩散模型不支持的语言生成图像（参见图 A.6）。更多细节请参见附录 A.9。

2.4 评测

2.4.1 定性比较

实验设置。我们将方法与 Stable Diffusion (SD) 与 SDXL 进行定性比较。选择 SD 系列作为布局锚定图像生成的基础模型，是因为其强大的能力以及在文生图研究中被广泛采用。得益于我们的训练自由特性，该方法无需任何额外训练即可适用于多种扩散模型。因此，对于图 2.1、图 2.7 和图 2.9，我们使用最大的 Stable Diffusion 模型 SDXL 作为 LMD 的基础模型，并与 SDXL 作为基线进行比较。除非另有说明，其他所有实验均使用 Stable Diffusion v1.5 作为基础模型。所有定性比较均使用 GPT-4 进行布局生成。

实验结果。如图 2.1 和图 2.7 所示，我们的两阶段文生图方法显著增强了基础模型的提示词遵循能力，生成的图像能够与 LLM 给出的布局对齐。

与其它基于 LLM 的图像生成器比较。Visual ChatGPT 和 GILL 同样将 LLM 作为图像生成流水线的一部分，且都使用 SD 作为底层图像生成模型。Visual ChatGPT 把 SD

视作 LLM 可以调用的模块，并把文本描述传给它；GILL 输出一个嵌入来替代 SD 的文本嵌入。由于这两种方法都仅以文本嵌入的形式让 LLM 为 SD 提供条件，因此它们仍然继承了基础 SD 模型在文本嵌入上的控制力不足问题。相比之下，我们的方法要求 LLM **显式推理空间关系**，并对底层扩散模型施加**直接的空间控制**，从而绕过了文本嵌入表征不能准确传达空间信息的瓶颈。如图 2.8 所示，对于本文方法能正确生成的多个提示词类别，这两种方法都不能准确遵循。此外，尽管 Visual ChatGPT 和 GILL 中的 LLM 参与也潜在地允许多轮指令式场景描述（小节 2.3），我们从经验上观察到：从第二轮开始，生成的图像便迅速偏离了“一张木桌”的场景，最终的生成结果已难以理解。

2.4.2 定量评估

提出的基准。我们提出了一套文生图评测基准，包含四项任务：**否定（Negation）**、**生成式计数（Generative Numeracy）**、**属性绑定（Attribute Binding）**、**空间推理（Spatial Reasoning）**。否定和生成式计数涉及生成特定数量的物体或不生成特定物体；属性绑定涉及在提示词中含多个物体时把正确的属性赋予正确的物体；空间推理涉及理解描述物体相对位置的词。每个任务我们以程序化方式组合 100 个提示词，对每个模型进行文生图查询，总计 400 个提示词。LMD 在基准测试中使用 GPT-3.5-Turbo。我们还实现了 LMD+——一种将预训练好的 GLIGEN 适配器集成进我们的控制器但不再做进一步训练的 LMD 变体。

基于检测的评估。我们使用开放词汇物体检测器 OWL-ViT 来获取感兴趣物体的边界框，然后检查每张生成图像是否满足提示词要求。每个任务的准确率按满足对应提示词要求的生成图像占全部生成图像的比例来计算。

实验结果。如表 2.1 所示，我们的方法在生成准确率上有显著提升，相对 SD 在四项任务上的提升幅度从 $1.3\times$ 到 $3.6\times$ 不等，平均准确率翻倍。特别地，LMD 在空间关系和否定任务上的图像生成准确率达到了 SD 准确率的两倍以上，这凸显了基于 LLM 布局生成器进行图像锚定的实用价值。此外，当额外将 GLIGEN 集成进我们的流水线以利用领域内的实例标注数据时，我们的方法（记作 LMD+）能获得进一步的提升。

表 2.1： LMD 与 LMD+ 在基准上的表现

任务	SD	LMD	LMD+
否定 (Negation)	28%	100% (3.6 $\times$)	100% (3.6 $\times$)
生成式计数 (Generative Numeracy)	39%	62% (1.6 $\times$)	86% (2.2 $\times$)
属性绑定 (Attribute Binding)	52%	65% (1.3 $\times$)	69% (1.3 $\times$)
空间关系 (Spatial Relationships)	28%	79% (2.8 $\times$)	67% (2.4 $\times$)
平均 (Average)	37%	77% (2.1 $\times$)	81% (2.2 $\times$)

2.4.3 消融实验

布局到图像阶段。与其他布局到图像方法的比较。如表 2.2 所示，与进行语义级锚定的训练自由布局到图像生成方法相比，我们提出的布局锚定控制器在实例级锚定上表现优异。事实上，我们无需任何实例标注训练出的训练自由控制器，在生成式计数任务上甚至超过了基于训练的 GLIGEN。此外，在属性绑定和空间推理任务上，我们的方法也显著优于基于训练的 GLIGEN。当与 GLIGEN 集成以利用实例标注数据集时（记作 LMD+），无需任何额外训练即可获得进一步提升。

不调超参数直接切换基础扩散模型。如表 2.3 所示，得益于我们训练自由的特性，当我们把基础扩散模型从 SDv1.5 切换到 SDv2.1 时，LMD 仍能保持相对基础模型约 2 $\times$ 的性能提升，且无需调整任何超参数，包括我们方法引入的 λ 和 ω 。这展示了将 LMD 与未来扩散模型集成的潜力。

使用 SAM vs. 简单注意力阈值获取逐框掩码。除了使用 SAM 获取每个框的掩码外，我们还探索了一种无需额外分割模块的方法。具体地，我们对每个框内像素按其与框描述的注意力值排序，选取注意力最高的 75% 像素作为该框的掩码。如表 2.4 所示，SAM 的影响对 LMD/LMD+ 不同。在 LMD 中，由于基于注意力的引导在空间上对布局框不够精确，SAM 有助于获得覆盖物体的正确掩码。因此，去除 SAM 会导致 LMD 性能略微下降。在 LMD+ 中，由于引导在空间上更精确，SAM 大多数情况下不再必要。相反，SAM 有时会选取包含背景的区域，造成混淆并降低性能。因此，去除 SAM 在 LMD+ 中反而能略微提升结果。我们将 SAM 作为可选组件（图 2.2 中说明），但仍建议在 LMD 中默认启用。

文本到布局阶段。上下文示例的消融。除了默认使用的七个固定上下文示例外，我们还改变了提供给 LLM 的上下文示例数量（即 “shots”）。表 2.5 显示：虽然 GPT-3.5 受益于更多的上下文示例，但 GPT-4 即便仅给出一个上下文示例也能成功生成所有布局。

我们还观察到 GPT-4 在没有任何上下文示例（即仅给出文本指令）的零样本情况下仍能生成布局。然而，由于这种零样本设置下没有任何示例作为参考，LLM 输出的格式在不同运行间会出现差异，难以被程序解析。**由于通过示例传达格式远比通过语言指令容易，我们建议至少给出一个示例。**我们的观察表明：LLM 已经在预训练过程中学会了生成物体框的能力，无需借助大量上下文示例即可获得。变更 LLM 的模型类型与规模。我们还对用于文本到布局生成的 LLM（包括使用公开权重的自托管 LLM）进行了消融。结果显示：生成高质量布局的能力并不局限于专有 LLM，更大的 LLM 能显著提供更好的布局生成能力。

2.4.4 基于评估者的主观评估

实验设置。我们还对方法及底层基础扩散模型 SD 的提示词遵循能力进行了评估。我们从所提基准中随机选择 10 条文本提示词，对每条提示词分别用本文方法 LMD+ 和基础模型 SD 生成一对图像¹。我们邀请了 11 位评估者比较每对图像并回答以下两个问题：

1. 问题 1：哪张图像与文本提示词对齐得更好？
2. 问题 2：哪张图像在前景-背景组合上更自然、连贯？

除选择任一图像的选项外，每对还提供“similar（差不多）”选项。

实验结果。我们对 110 份回复进行平均。LMD+ 在第一个问题上获得了 88.18% 的胜率（SD 为 10.90%），在第二个问题上获得了 35.45% 的胜率（SD 为 31.81%）。这表明：**与基线 SD 相比，本文方法生成的图像与提示词对齐更准确，同时未损失自然性与连贯性。**

2.5 讨论

由于我们使用的是现成模型，LLM 可能会生成对扩散模型来说有歧义的布局。例如，图 2.9(b) 中的布局对于自上而下的特写镜头是合理的，但扩散模型却生成了侧视图的图像，导致苹果不在桌面上的图 2.9(c)。通过提示或微调 LLM 让布局中的假设（例如视角）更明确，可以缓解这一问题。**我们的两阶段生成中，中间布局比基础模型 Stable Diffusion 提供了更好的可解释性。**在定位失败点之后，我们向 LLM 给出关于侧视图和正确物体大小的额外请求，LLM 调整了后续布局生成，从而能够在第二轮生成与输入提示词一致的图像（如图 2.9(d,e) 所示）。

¹LMD+ 的基础模型严格来说是 GLIGEN，而 GLIGEN 又是基于 SD 搭建的。但在本文设定中仅使用文本作为输入时，GLIGEN 的条件机制退化为无效，因此我们直接与 SD 进行比较。

我们的方法还继承了基础扩散模型的偏差。此外，尽管我们的方法能处理上下文示例中未提及的物体（例如图 2.7 中的熊和鹿），但 LLM 仍可能通过参考布局示例，对示例中提及的物体生成更好的布局。我们的方法还可以蒸馏到一个单阶段文生图扩散模型中，在推理时不依赖 LLM 即提升其提示词理解能力，便于部署。

2.6 小结

在本文中，我们增强了文生图扩散模型的提示词理解能力。我们提出了一种全新的、训练自由的两阶段生成过程，将大语言模型作为强大的提示词理解工具融入扩散模型的图像生成流水线。LLM-grounded Diffusion (LMD) 通过 LLM 提供的中间布局表示，对图像生成施加显式空间控制，显著提升了模型在否定、计数、属性绑定、空间推理等任务上的能力。我们的方法无需任何额外的训练或微调，即可直接应用于现成的 LLM 和扩散模型，并在多项任务上相对基础模型取得了一倍以上的提升。同时，借助 LLM 的对话能力，LMD 还能自然而然地支持多轮指令化的场景描述，进一步提升用户的创作体验。

译注：本译稿已翻译原文“摘要 (Abstract)”、“第 1 章引言 (Introduction)”、“第 2 章 LLM-grounded Diffusion”以及“第 3 章 LLM-grounded Video Diffusion”全文。后续章节（第 4-9 章及附录）仍待翻译，如需进一步翻译可分批进行。

3 LLM 锚定的视频扩散模型

本章基于以下已发表论文：

Long Lian, Baifeng Shi, Adam Yala, Trevor Darrell, Boyi Li. “LLM-grounded Video Diffusion Models.” *International Conference on Learning Representations (ICLR)*, 2024.

3.1 引言

近年来，文生图（text-to-image）生成取得了显著进展。其中，扩散模型在生成高质量视觉内容方面展现了令人印象深刻的能力。然而，文生视频（text-to-video）生成更具挑战性，原因在于视频涉及复杂的时空动力学（spatiotemporal dynamics）。近期的工作提出了专门面向视频的扩散模型，旨在捕捉输入提示词中的时空动力学。然而，这些方法仍然难以生成与提示词一致的合理空间布局或时间动力学，参见图 3.1。

尽管让扩散模型直接根据文本提示生成复杂动力学极其困难，一种可能的“曲线救国”思路是：先从提示词生成显式的时空布局（spatiotemporal layouts），再借助这些布局去引导扩散模型。事实上，近期一些文生图研究 [?, ?, ?] 已经提出用 LLM 生成空间排列，并用其作为条件来控制文生图模型。这些研究表明：LLM 拥有令人惊喜的能力，能根据文本提示生成每个物体的精确边界框坐标；这些边界框又可以进一步用于控制扩散模型，从而增强生成图像的空间关系一致性。但是，LLM 是否能够同时在空间与时间两个维度上为视频生成动态场景布局，仍然是一个未被证明的问题。这样的布局生成是一个难度高得多的问题，因为物体的运动模式往往既依赖于其物理属性（如重力），又依赖于物体本身的特性（如弹性 vs 刚性）。

在本文中，我们探究 LLM 是否能够生成与给定文本提示一致的时空边界框。一旦生成，这些跨越多帧的边界框序列（即动态场景布局，Dynamic Scene Layouts，简称 DSL）便可以作为一种中间表示，架起文本提示与视频之间的桥梁。借助一种简洁而有效的注意力引导算法，这些由 LLM 生成的 DSL 可以被用来以训练自由（training-free）的方式控制物体级空间关系与时间动力学的生成。整个方法被称为 LLM-grounded Video Diffusion (LVD)，如图 3.2 所示。如图 3.1 所示，LVD 生成了符合指定时间动力学、物体属性以及空间关系的视频，从而大幅提升了输入提示与生成内容的一致性。

为了评估 LVD 在生成与提示词一致的空间布局和时间动力学方面的能力，我们提出了一套包含五个任务的基准测试，每个任务都要求理解与生成提示词中不同的空间与时间

属性。我们证明：LVD 相比多个强基线模型，在**文本-视频对齐**上取得了显著改进。我们还在常见的数据集（如 UCF-101 [?] 与 MSR-VTT [?]) 上对 LVD 进行了评测，并进行了人工评估，结果显示 LVD 相对其底层扩散模型取得了稳定的提升。

本章主要贡献：

1. 证明了纯文本 LLM 能够生成可泛化到未见过的时空序列的动态场景布局。
2. 提出了 **LLM-grounded Video Diffusion (LVD)**，这是首个利用 LLM 生成的动态场景布局来提升复杂文本提示视频生成能力的**训练自由**流水线。
3. 引入了一套基准测试，用于评估文本提示与文生视频模型生成视频之间的一致性。

3.2 相关工作

可控扩散模型。扩散模型在内容创作领域大获成功 [?, ?, ?, ?, ?, ?, ?, ?]。ControlNet [?] 提出了一种架构设计，将神经网络中的空间条件控制融入到大规模预训练文生图扩散模型中；GLIGEN [?] 引入门控注意力适配器以接收额外的锚定信息用于图像生成；Shape-guided Diffusion [?] 让预训练扩散模型能响应用户给定的或从文本推断出的形状输入；Control-A-Video [?] 训练模型基于控制信号序列（如边缘图、深度图）生成视频。尽管这些工作取得了令人瞩目的进展，**仅基于文本提示生成具有复杂动力学的视频这一挑战仍然悬而未决。**

文生视频生成。虽然视频生成文献丰富 [?, ?, ?, ?, ?, ?, ?]，但文生视频生成仍然充满挑战——它要求模型**仅凭文本**综合出视频动力学。Make-A-Video [?] 分解了完整的时空 U-Net [?] 与注意力张量，并在空间与时间两个维度上做了近似，构建了高分辨率视频生成的流水线。Imagen Video [?] 通过基础视频生成模型与时空超分辨率模型生成高清视频。Video LDM [?] 通过向潜在空间扩散模型增加时间维度，把图像生成器改造成视频生成器。Text2Video-Zero [?] 引入了两种后处理技术以保证时间一致性：在潜码中编码运动动力学、用跨帧注意力机制重编程帧级自注意力。然而，**这些模型仍然容易在生成合理的视频动力学方面翻车**，原因是缺乏覆盖多样运动模式与物体属性的大规模配对文本-视频训练数据，更不用说训练这种规模数据集所需的算力成本。

基于大语言模型的锚定与推理。近期多项文生图模型都提出：将输入文本提示送入 LLM 以获得合理的空间边界框，并基于这些框生成高质量图像。LMD [?] 提出了一种**训练自由**方法，借助创新控制器使用 LLM 生成的布局来引导扩散模型；LayoutGPT [?] 提出了一

种程序引导的方法，将 LLM 应用于多领域的布局式视觉规划；Attention Refocusing [?] 提出了两种新颖的损失函数，根据指定布局重新对齐注意力图。这些方法共同提供了实证证据：LLM 生成的边界框对控制文生图生成既准确又实用。受此启发，本章的目标是**提升文生视频模型在包含复杂动力学的提示词上的生成能力**。我们致力于通过挖掘并利用 LLM 在生成视频空间与时间动力学方面的潜力来实现这一点。一篇并行工作 VideoDirectorGPT [?] 也提出在多场景视频生成中使用 LLM，但其关注点与技术路线不同——它探索训练扩散适配器以接收额外的条件信号，而 LVD 聚焦于**推理时引导**以及对 LLM 泛化能力的深入分析。

3.3 大语言模型能生成时空动力学吗？

在本节中，我们探究 LLM 能在多大程度上生成与指定文本提示一致的时空动力学。我们旨在回答三个问题：

1. LLM 是否能生成与文本提示一致的**真实动态场景布局（DSL）**，并辨别何时应用特定的物理属性？
2. LLM 对这些属性的理解究竟来自它的参数权重，还是在推理过程中临时习得？
3. 在仅展示有限关键属性的示例条件下，LLM 是否能泛化到更广泛的世界概念和相关属性？

向 LLM 提示动力学生成的方式。我们向 LLM 查询的提示由两部分组成：**任务说明文字**与**几个示例**，用以展示期望的输出格式与需遵守的规则。给出提示后，我们要求 LLM 完成续写，由此生成动力学。

任务说明。我们要求 LLM 充当“视频边界框生成器”。在任务设定中，我们明确说明坐标系、画布尺寸、帧数与帧速等任务要求。

DSL 表示。我们要求 LLM 用一个 **Dynamic Scene Layout（DSL）** 来表示每个视频的动力学，DSL 是一组**跨帧链接**的边界框。我们提示 LLM 顺序生成每一帧中可见的边界框。每个框的表示包括该框在数值坐标下的位置与大小，以及一段描述框内物体的短语。每个框还有一个从 0 开始的**数字标识符**，跨帧的框通过分配的 ID 进行匹配，**无需借助任何目标跟踪器**。

上下文示例。LLM 可能不会理解我们在 DSL 生成中对真实世界动力学（如重力）的需求，这会导致一些与我们的具体目标不一致的假设。为正确引导它们，我们提供了若干示例，凸显生成自然时空布局所需的物理属性。一个关键问题由此浮现：**鉴于 LLM 并非为真实世界动力学而设计，它们究竟需要多少示例才能生成真实布局？**人们或许以为需要大量提示才能让它掌握框坐标背后复杂的数学与真实动力学。然而，与直觉相反，我们发现：**只需为每项期望属性提供一到两个示例，并辅以少量体现关键物理属性的示例，便常常足以让 LLM 理解物理属性与相机运动等各方面，进而支撑下游视频生成应用（小节 3.4）。**我们还发现：**LLM 能从提供的示例中“举一反三”，推断出未显式提及的相关属性。**这意味着我们并不需要罗列每一项期望属性，只需突出几个主要的即可。我们的上下文示例可视化于图 3.3。

先推理，再生成。为提升 LLM 输出的可解释性，我们要求 LLM 在开始为每一帧生成边界框之前，先输出一段简短的**推理说明**。我们还在每个上下文示例中加入对应的推理说明，以匹配输出格式。

探究设定。鉴于视频生成的下游需求，我们将期望的物理属性分为**世界属性与相机属性**两类。具体而言，我们考察**重力与物体弹性**作为世界属性，考察**透视投影**作为相机属性。然而，LLM 出人意料的泛化能力表明，它有望泛化到我们尚未考察的其它属性。如图 3.3 所示，我们为上述三个属性各提供了一个示例。随后我们用少量世界属性和相机属性的文本提示来查询 LLM（参见图 3.4）。本节探究使用 GPT-4 [?]; 其它模型在小节 3.5 中讨论，结果验证它们也展现类似能力。

主要发现。我们发现，在各种查询情境下，无论是已见过的还是未见过的情况，LLM 都能生成与提示词一致的、真实的 DSL。值得注意，**这种能力植根于 LLM 的内在知识，而非仅仅依赖所提供的示例。**例如，给定展现弹性的”小球”示例（图 3.3(b)），LLM 能理解：无论球是从左侧（图 3.4(a)）还是右侧被抛出，**球落地后都会反弹**。更进一步，LLM 还能泛化到弹性不同的物体。例如，当把球换成石头、但不更新上下文示例（图 3.4(b)）时，LLM 会识别出石头没有弹性、不会反弹，但仍受重力作用下落。这种理解在我们的指令和示例中都没有关于石头属性的任何显式文字提示下达成。由于这种能力并非源自输入提示，**它必然源自 LLM 参数权重中存储的知识。**

为进一步说明这一点，我们在图 3.3(c) 中展示 LLM 掌握了“想象中的相机”遵循透视几何原理：相机远离画作时，画作看起来会变小。然后我们用图 3.4(e, f) 中**未经示例直接教学**的场景测试 LLM。即便没有任何关于”透视几何如何随相机视角与物体运动变

化”的显式解释，LLM 也能把握这个概念：如果汽车的前进方向与相机拍摄方向**垂直**，则透视几何原则**不再适用**。

更具说服力的是，通过设定恰当的“想象世界”上下文，LLM 还能对指令和示例中未指定的属性做出合乎逻辑的扩展。如图 3.4(d) 所示，LLM 认识到透视几何原则**不仅在相机远离静止物体时适用**（如图 3.3(c) 所介绍），**在物体远离静止相机时同样适用**——这种理解超出了我们给出的示例范围。如图 3.4(c) 所示，即便没有显式提到空气阻力，LLM 也会为纸飞机考虑空气阻力，生成的 DSL 中纸飞机下落更慢、滑翔距离更远。这表明：**我们的示例帮助 LLM 建立起一个可模拟的“想象世界”，从而无需对每一种可能场景做穷举式的提示**。LLM 还在推理说明中展现了对浮力与动物运动模式的理解，从而为图 3.1 那种场景生成真实的 DSL。

上述观察表明，LLM 仅凭图 3.3 中的三个上下文示例，就能成功生成与复杂提示词一致的 DSL。因此，我们在后续评测中就以这三个上下文示例为准，并在小节 3.5 给出进一步的定量与定性分析。

3.4 DSL 锚定的视频生成

借助 LLM 从文本提示生成 DSL 的能力，我们引入一种基于 DSL 引导视频合成的算法。我们的 DSL 锚定视频生成器（DSL-grounded video generator）引导一个**现成的**文生视频扩散模型，生成同时与**文本提示**和**给定 DSL** 均保持一致的视频。**我们的方法不需要微调**，因此无需实例标注的图像或视频数据，也避免了训练可能导致的灾难性遗忘。

文生视频扩散模型（如 ModelScope [?]) 通过接收形状为 $N \times H \times W \times C$ 的随机高斯噪声来生成视频，其中 N 为帧数， C 为通道数。骨干网络（通常为 U-Net [?]) 基于上一步的输出与文本提示迭代地去噪输入，而文本条件注入则通过将文本信息融入潜在特征的**交叉注意力层**实现。对于每一帧，我们记从潜在层到提示词中物体名称的交叉注意力图为 $A \in \mathbb{R}^{H \times W}$ ，其中 H 、 W 是潜在特征图的高与宽。为简洁起见，我们省略去噪声、潜在层、帧、物体索引等下标。**交叉注意力图通常会高亮物体生成的位置**。

如图 3.6 所示，为确保物体在 DSL 给定的边界框内生成并随框移动，我们鼓励交叉注意力图集中在对应的边界框内。具体而言，我们将 DSL 的每个框转换为一个掩码 $M \in \mathbb{R}^{H \times W}$ ，其中框内为 1、框外为 0。然后我们定义如下能量函数：

$$E_{\text{topk}} = -\text{Topk}(A \cdot M) + \text{Topk}(A \cdot (1 - M)) \quad (8)$$

其中 $\cdot$ 表示逐元素乘积, Topk 取矩阵中 top-k 值的平均值。直观上, 最小化该能量函数鼓励至少有 k 个高注意力值位于框内, 同时框外仅有低值。

然而, 如果连续帧的布局框大面积重叠 (即物体移动缓慢), E_{topk} 可能导致位置控制不精确。这是因为在重叠区域内的静止物体同样能最小化能量函数, 而文生视频扩散模型往往倾向于生成静止物体。为进一步保证生成物体的时间动力学与 DSL 引导一致, 我们提出了质心能量函数 E_{CoM} , 鼓励 A 与 M 的质心具有相似的位置与速度。记第 t 帧注意力图与框掩码的质心分别为 p_t^A 与 p_t^M , 则:

$$E_{\text{CoM}} = \|p_t^A - p_t^M\|_2^2 + \|(p_{t+1}^A - p_t^A) - (p_{t+1}^M - p_t^M)\|_2^2 \quad (9)$$

总体能量 E 是 E_{topk} 与 E_{CoM} 的加权和。

为最小化能量 E , 我们在每次扩散步前增加一个 DSL 引导步: 对每一帧、每一个物体, 计算能量相对部分去噪视频的梯度, 并通过分类器引导 (classifier guidance) [?, ?, ?, ?, ?, ?] 沿梯度下降方向更新部分去噪视频。

通过这种简洁而有效的训练自由条件注入阶段, 我们就能够用 DSL 控制视频生成, 从而打通 LVD 的完整流水线: 文本提示 $\rightarrow$ DSL $\rightarrow$ 视频。此外, LVD 的两个阶段与具体实现解耦, 可以方便地替换为更强的 LLM 或布局条件视频生成器, 意味着随着 LLM 与视频生成器的能力提升, 生成质量与文本-视频对齐也将持续提升。在图 3.5 中, 我们展示了 DSL 锚定的视频生成器能够根据图 3.4 中的 DSL 生成真实的视频。

3.5 评测

3.5.1 实验设置

基础模型。 我们选择 ModelScope [?] 作为基础视频扩散模型, 并在其之上应用 LVD。除了与不带 DSL 引导的 ModelScope 基线比较外, 我们还将 LVD 与一种基于检索的基线进行对比。给定一段文本提示, 该基线在大型视频字幕数据集 WebVid-2M 上基于 Frozen-In-Time [?] 计算的提示-视频相似度做最近邻检索, 然后运行 GLIP [?] 提取检索到视频字幕中实体的边界框, 并用 SORT [?] 跟踪边界框以得到 DSL。

基准测试。 为评估生成的 DSL 与视频与文本提示的对齐度, 我们提出了一套包含五个任务的基准: 生成式计数 (generative numeracy)、属性绑定 (attribute binding)、可

见性（visibility）、空间动力学（spatial dynamics）、顺序动作（sequential actions）。每个任务包含 100 条程序化生成的提示词，可基于 DSL 生成或基于规则化方法检测到的边界框进行验证，总计 500 条提示词。我们对每条提示词使用不同随机种子生成两个视频，因此每次评测共计 1000 个视频样本。我们随后报告遵循文本提示的视频比例。此外，我们还采用文献 [?, ?] 中引用的常见基准（UCF-101 [?] 与 MSR-VTT [?]) 评估视频生成质量，并进行了人工评估。评估设置与基准测试的更多细节请参见附录 B.4。

表 3.1: 生成 DSL 的评测。我们的 LLM 时空规划器能在多种类型的提示词下生成符合时空动力学要求的布局。

方法	计数	属性绑定	可见性	动力学	顺序动作	平均
基于检索	20%	12%	28%	8%	0%	14%
LVD (GPT-3.5)	100%	100%	100%	71%	16%	77%
LVD (GPT-4)	100%	100%	100%	100%	88%	98%
+ 检索示例	98%	100%	100%	96%	85%	96%

表 3.2: 基于检测的视频评测。LVD 在遵循提示词中的时空关键词方面优于其底层的 ModelScope 扩散模型。生成视频分辨率为 256×256 。

方法	计数	属性绑定	可见性	动力学	顺序动作	平均
ModelScope	32%	54%	8%	21%	0%	23.0%
基于检索	15%	15%	11%	9%	0%	9.7%
LVD (GPT-3.5)	52%	79%	64%	37%	2%	46.4%
LVD (GPT-4)	41%	64%	55%	51%	38%	49.4%

3.5.2 生成 DSL 的评测

我们评测 LLM 生成的 DSL 与文本提示的对齐度，而不涉及最终的视频生成。表 3.1 给出结果。首先，我们与一种直接以检索到的最相似视频的布局作为 DSL 输出、不涉及 LLM 的基线方法对比。它的低性能表明：基于文本-视频相似度的最近邻检索常常无法定位具有匹配时空布局的视频。与之相比，我们的方法生成的 DSL 与查询提示对齐度好得多——使用 GPT-3.5 即可取得 77% 的平均准确率，使用 GPT-4 更是达到了惊人的 98% 平均准确率。这些结果表明：当前纯文本 LLM 仅凭文本提示就能生成合理的时空布局，而这是基于检索的方案很难做到的。值得注意的是，整个评测中只用了图 3.3 中的三个上下文示例。为了判断引入真实视频示例是否会提升性能，我们实验性地

加入了来自检索的样本。然而，这些额外示例带来的性能类似，凸显了 LLM 强大的少样本泛化能力。我们还观察到 GPT-3.5 在顺序动作任务上表现吃力——它通常一开始正确，但要么跳过两个动作之一，要么将两个动作同时执行。

3.5.3 生成视频的评测

视频-文本对齐评测。我们接下来评估生成的视频是否遵循文本提示中所描述的空间布局与时间动力学。评测同样采用基于规则的方法，使用 OWL-ViT [?] 检测得到的边界框。表 3.2 的结果显示：ModelScope 在大多数场景下表现不佳，在五个任务中有两个几乎生成不出合格视频。此外，基于检索的视频布局的文本-视频对齐性能比 ModelScope 基线还差。另一方面，LVD 显著超越两个基线，幅度可观，表明所提出的 LVD 流水线在视频-文本对齐上有明显改进。有趣的是，GPT-3.5 生成的布局在三个任务上反而带来了更好的文本-视频对齐，原因是这些布局整体运动幅度较小，更容易从其生成视频。表 3.1 与表 3.2 之间的差距仍然表明：瓶颈在于 DSL 锚定的视频生成阶段。

能量函数的消融。Boxdiff [?] 在 E_{topk} 之外提出了角点项 E_{corner} ，文献 [?] 提出了基于比例的能量 E_{ratio} 。表 3.3 显示：仅使用 E_{topk} 就能取得良好的文本-视频对齐。我们还建议：当涉及顺序动作任务时加入 E_{CoM} ，它能带来显著提升。

表 3.3：视频扩散模型布局条件能量函数的消融。所有实验使用 LLM（GPT-4）生成的同一套布局。文献 [?] 提出的 E_{ratio} 与 Boxdiff [?] 的 E_{corner} 都不能进一步提升文本-视频对齐，而仅用 E_{topk} 就己能取得良好效果；进一步加入 E_{CoM} 在顺序动作任务上带来显著提升。生成视频分辨率为 256×256 。

E_{topk}	E_{ratio}	E_{corner}	E_{CoM}	计数	属性绑定	可见性	动力学	顺序动作	平均
×	✓	×	×	44%	53%	11%	54%	21%	36.4%
✓	×	✓	×	38%	60%	53%	48%	31%	45.6%
✓	×	×	×	39%	65%	54%	52%	23%	46.3%
✓	×	×	✓	41%	64%	55%	51%	38%	49.4%

视频质量评测。由于本文的主要目标是在无需额外训练的前提下生成与复杂文本提示一致的视频，改进视频画质并非本文的核心目标。我们通过 UCF-101 与 MSR-VTT 上的 FVD 分数评估视频质量。FVD 分数衡量生成的视频与数据集分布的接近程度。这两个基准都包含复杂人类动作或真实世界运动的视频。由于我们的方法与底层模型解耦且适用于不同的文生视频扩散模型，我们主要与底层扩散模型 ModelScope [?] 比较。LVD 与

我们复现的 ModelScope 均生成 256×256 视频。如表 3.4 所示，LVD 在两个数据集上的生成质量均优于 ModelScope 基线，表明我们的方法能生成在视觉上更接近真实世界视频的动作与运动。ModelScope 与 LVD 在 MSR-VTT 上超越了 MagicVideo [?] 等模型，而在 UCF-101 上表现较差，可能源于训练数据差异。

表 3.4: 视频质量评测。FVD 越低越好。† 标记为我们复现的结果。LVD 在两个基准上的视频质量均优于 ModelScope。

方法	FVD@UCF-101 (↓)	FVD@MSR-VTT (↓)
CogVideo (中文) [?]	751	—
CogVideo (英文) [?]	702	1294
MagicVideo [?]	699	1290
Make-A-Video [?]	367	—
VideoLDM [?]	551	—
ModelScope [?]	—	550
ModelScope [†]	984	590
ModelScope w/ LVD (本文)	828	565

可视化。图 3.7 展示了 LVD 与 ModelScope 基线的视频生成结果。LVD 在以下方面稳定优于基础模型：生成正确的物体数量、管理视频中间段物体的引入、遵循提示词中指定的顺序方向。此外，LVD 也能很好地处理多物体描述。例如图 3.7(b) 中，ModelScope 把”狗”的颜色错配给球，而 LVD 则精准地捕捉到了”蓝色的狗”和”棕色的球”。

人工评估。为进一步验证 LVD 生成视频的质量，我们开展了一项人工评估。我们向 10 位参与者提出两个问题，针对从基准中随机抽取的 20 对视频：“哪个视频与文本提示更对齐？”与“哪个视频画质更好？”。每对视频由基线与 LVD 各自生成的视频组成，且在每对内做了随机打乱。对每个问题，选项均为“视频 #1”、“视频 #2”和“差不多”。表 3.5 给出平均得分。**LVD 显著优于基线：**在 96.8% 的对齐比较与 85.5% 的画质比较中，评估者认为 LVD 优于或至少与基线模型持平。这凸显了 LVD 在对齐和视觉质量两方面均显著提升了基线视频扩散模型的性能。

表 3.5: 基于人类评估者的评价。尽管 LVD 与基线模型 [?] 共享相同的扩散权重，LVD 被显著更频繁地偏好。

问题	基线	LVD	差不多
哪个视频与文本提示更对齐?	3.2%	85.8%	12.6%
哪个视频画质更好?	14.5%	66.0%	19.5%

3.6 讨论与未来工作

本章提出了 LLM-grounded Video Diffusion (LVD)，用于在不更新任何 LLM 或扩散模型参数的前提下，提升文生视频扩散模型处理复杂提示词的能力。尽管 LVD 已显示出对现有方法的实质性增强，但仍存在进一步改进的空间。例如，LVD 在合成其底层模型本就难以处理的物体或艺术风格时，仍会继承这些局限性。我们预期 LoRA 微调 [?] 等技术可以缓解这些挑战，并将其留作未来工作。本章工作的目标有两个：（1）展示 LLM 出人意料的时空建模能力；（2）展示基于 LLM 的中间表示（如 DSL）可以用来提升文生视频生成的对齐度，并有望进一步扩展到对人体姿态等更细粒度属性的控制，从而建模更复杂的动力学。我们的 DSL 到视频阶段仍较为简单，因此未来工作中更先进的 DSL 条件视频生成器有望进一步提升控制精度与视频质量。

可复现性声明。本文主要在开源模型 ModelScope [?] 上应用与评测我们的方法，便于复现本文结果。我们也将发布代码与基准测试，方便后续研究复现与对比。

4 自纠正的 LLM 控制扩散模型

本章基于以下已发表论文（同等贡献标注*）：

Tsung-Han Wu*, Long Lian*, Joseph E. Gonzalez, Boyi Li, Trevor Darrell. “Self-correcting LLM-controlled Diffusion Models.” *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

4.1 引言

文生图生成近年来取得了显著进展，尤其是扩散模型的崛起。然而，这些模型在理解复杂输入文本提示词方面仍常常力不从心，尤其是那些需要理解计数概念、空间关系和多物体属性绑定的提示词。尽管模型规模和训练数据惊人地增长，如图 4.1 所示，这些挑战在目前最先进的开源与商业扩散模型中仍然普遍存在。

多种研究与工程努力试图克服这些局限。例如 DALL-E 3 聚焦于扩散训练过程，在大规模训练数据中加入了高质量字幕。然而，这种方法不仅耗费巨大，在面对复杂用户提示词时也常常无法生成精确图像。另有工作借助外部模型，在实际图像生成之前更好地理解提示词。例如，文献利用 LLM 将文本提示词预处理为结构化图像布局，从而保证初步设计与用户指令一致。然而，这种整合方式并不能解决下游扩散模型产生的偏差，特别是在多物体、杂乱布局或精细属性等复杂场景图像中。

受人类画师作画过程与扩散模型生成图像之间差异的启发，我们观察到一个关键区别：假设有一位人类画师被要求画一幅包含两只猫的场景。在整个作画过程中，这位画师始终牢记这一要求，确保在作品完成之前确实存在两只猫——如果发现画中只有一只，他会再添一只以满足提示词的要求。这与当前文生图扩散模型形成了鲜明对比——这些模型以“开环”方式运作：按照预设数量的扩散步生成图像，然后将输出呈现给用户，无论其与初始用户提示词的一致性如何。这种过程，无论如何扩大训练数据规模或加入 LLM 预生成条件，都缺乏一种健壮机制来保证最终图像与用户期望相符。

为此，我们提出 Self-correcting LLM-controlled Diffusion (SLD) ——一种通过自我检查为用户提供图像与提示词对齐保证的自纠正方法。SLD 摒弃了传统单轮生成方法，是一种全新的闭环（closed-loop）方法，赋予扩散模型迭代识别并修正错误的能力。我们的 SLD 框架包含两个主要组件：LLM 驱动的对象检测以及 LLM 控制的评估与修正。

SLD 流水线遵循标准文生图生成设置。给定一个概述目标图像的文本提示词，SLD 首先调用图像生成模块以”尽力而为”的方式生成图像。由于这些开环生成器无法保证输出与提示词完美对齐，SLD 随后用 LLM 解析关键短语并送入开放词汇检测器，对生成图像进行与提示词的全面对齐评估。接下来，**LLM 控制器**以检测到的边界框和初始提示词为输入，检查检测结果与提示词要求之间可能存在的不匹配，并提出恰当的自我修正操作（如添加、移动、删除物体）。最后，SLD 利用基础扩散模型的**潜空间组合**来实施这些调整，从而保证最终图像准确反映用户的初始文本提示词。

值得注意的是，我们的流水线对初始生成的来源没有任何限制，因此可应用于由商业模型（如 DALL-E 3）通过 API 生成的图像。此外，所有自我修正操作都**无需在基础扩散模型上进行任何额外训练**，使我们的方法易于应用于各种扩散模型，无需外部人工标注或训练的成本。

我们证明了 SLD 框架在 LMD 基准上对复杂提示词的处理方面取得了显著改进。结果表明，我们的方法能够超越 LMD+——后者本身已是一个在图像生成流水线中充分利用了 LLM 的强基线——提升 9.0%。更重要的是，使用 DALL-E 3 做初始生成时，我们的方法相对于自纠正前的图像实现了 26.5% 的性能提升。

此外，由于 SLD 流水线与初始生成的图像无关，它只需简单改变给 LLM 的提示词，就能轻松转变为**图像编辑流水线**。

文生图生成与图像编辑通常被生成式建模社区视为两个不同任务，而 SLD 能够用统一流水线完成这两项任务。我们列出主要贡献：

1. SLD 是首个将检测器与 LLM 整合以自我纠正生成模型的方法，**无需额外训练或外部数据即可保证精确生成**。
2. SLD 提供了图像生成与编辑的**统一解决方案**，能够为任意图像生成器（如 DALL-E 3）增强文本-图像对齐，并支持对任意图像进行物体级编辑。
3. 实验结果表明，我们的方法能够修正大多数不正确的生成，尤其在**计数、属性绑定和空间关系**方面。

4.2 相关工作

文生图扩散模型。基于扩散的文生图生成已取得显著进展。早期研究展示了扩散模型创建高质量图像的能力，但在复杂提示词面前仍显吃力。后续研究引入了关键点、边界框

等额外输入来控制扩散生成过程。近期进展已引入 LLM 来控制扩散模型的生成，无需额外互补信息作为输入。在这些方法中，LLM 扮演核心角色，直接解释用户文本提示并管理初始布局配置。尽管有所进展，但这些模型通常以开环方式运作——单次迭代生成图像，无法保证生成的图像与用户提示词对齐。

与之前工作不同，SLD 是首个闭环的基于扩散的生成方法。通过整合先进的物体检测器和 LLM，SLD 执行迭代的自我检查与修正，显著增强了文本-图像对齐。这种改进覆盖了计数、多物体属性绑定和空间推理，适用于包括 DALL-E 3 在内的各种模型。

基于扩散的图像编辑。文生图扩散模型的最新进展显著扩展了其在图像编辑中的应用，涵盖全局与局部编辑任务。Prompt-2-Prompt 和 InstructPix2Pix 等技术专注于全局编辑（如风格转换）；SDEdit、DiffEdit 和 Plug-and-Play 等方法专注于局部编辑。尽管有所进展，这些方法在**精确物体级操控**和需要空间推理的任务方面仍力不从心。虽然 Self-Guidance 等近期方法提供了细粒度操作，但仍需要用户在移动或重新定位物体时提供具体的坐标输入。

与这些仅关注扩散模型的方法不同，SLD 引入检测器与 LLM 到编辑循环中，实现了**仅凭用户提示词即可进行细粒度编辑**。此外，SLD 在各种物体级编辑任务中表现出色，包括添加、替换、移动、修改属性、交换等，展示了在使用便捷性与编辑能力两方面的显著提升。

4.3 自纠正的 LLM 控制扩散模型

在本节中，我们介绍我们的 Self-correcting LLM-controlled Diffusion (SLD) 框架。SLD 包含两个主要组件：**LLM 驱动的物体检测**与**LLM 控制的评估与修正**。只需简单改变 LLM 的指令，我们就能展示 SLD 同样适用于图像编辑，从而将文生图生成与编辑统一为同一流水线。完整流水线如算法 1 所示。

4.3.1 LLM 驱动的物体检测

我们的 SLD 框架以 LLM 驱动的物体检测作为起点，提取下游评估与修正所需的信息。LLM 驱动的物体检测包含两个步骤：

步骤一：我们利用 LLM 作为**解析器**，解析用户提示词并输出与图像评估可能相关的关键短语。在文本指令和上下文示例的辅助下，这个解析器可以轻松完成该任务。对于包含”a green motorcycle”和”a blue motorcycle”的用户提示词，LLM 应识别并输

出“green”和“blue”作为与“motorcycle”关联的属性。当提示词中引用的物体没有具体数量或属性（如“a monkey”和“a raccoon”），这些描述符则留空。重要的是，LLM 的作用不限于识别物体名词本身，还包括识别任何关联的数量或属性。

步骤二：开放词汇物体检测器处理第一步中解析出的关键物体信息列表 S ，检测并定位图像中的物体。我们以“image of a/an [attribute] [object name]”格式的查询提示开放词汇物体检测器。得到的边界框 B_{curr} 被组织成列表格式，如 “[([attribute] [object name] [#object ID]), [x, y, w, h]]”，以便进一步处理。一种特殊情况是当提示词对物体数量有约束时：若带属性的物体（如“blue dog”）数量不足，我们提供不带属性的物体（如“dog”）的补充计数，为后续 LLM 控制器决定是添加更多“blue dogs”还是将已有狗的颜色改为蓝色提供上下文。

4.3.2 LLM 控制的分析与修正

我们使用 LLM 控制器进行图像分析与后续修正。控制器接收用户提示词 P 与检测到的边界框 B_{curr} ，判断由边界框表示的图像是否与用户提示词描述一致，并给出修正后的边界框列表 B_{next} 。

SLD 然后程序化地分析修正后与原始边界框之间的不一致，输出一组编辑操作 Ops ，包括添加（addition）、删除（deletion）、重新定位（repositioning）和属性修改（attribute modification）。然而，简单的边界框集合表示不携带对应关系信息，当多个框共享同一物体名称时，无法轻松比较 LLM 控制器的输入与输出布局。我们没有引入另一种算法来猜测对应关系，而是提出让 LLM 在输出中直接包含对应关系——方法很简单：给每个边界框分配一个物体 ID，在每种物体类型内编号递增，作为物体名称后缀。

4.3.3 无需训练的图像修正潜空间操作

LLM 控制器输出一组待实施的修正操作。对于每个操作，我们首先将原始图像转换为潜特征，然后对这些潜层执行一系列操作 Ops 。

添加（Addition）。受 LMD 启发，添加过程包含两个阶段：**预生成物体**，并将其潜表示集成到原始图像的潜空间中。首先，我们使用扩散模型在指定边界框内生成一个物体，然后使用 SAM 进行精确分割。该物体随后通过基础扩散模型的反向扩散序列处理，生成对应物体的掩码化潜层，最后与原始画布合并。

删除（Deletion）。删除操作首先用 SAM 精修边界框内物体的边界。然后，将与这些指

定区域关联的潜层移除并重置为高斯噪声。这要求在随后的前向扩散过程中对这些区域进行完整重建。

重新定位 (Repositioning)。重新定位涉及修改图像以使物体与新边界框对齐，同时注意保持其原始宽高比。初始步骤包括在图像空间中移动和调整边界框。随后 SAM 精修物体边界，接着是反向扩散过程以生成其相关潜层。被切除部分的潜层被替换为高斯噪声，而新添加的部分则集成到最终图像合成中。**重新定位的一个重要考虑因素是：应在图像空间而非潜空间中调整物体大小，以保持高质量结果。**

属性修改 (Attribute modification)。属性修改首先用 SAM 精修边界框内物体的边界，然后应用 DiffEdit 等属性修改。基础扩散模型随后反向处理图像，生成一系列掩码化潜层，准备最终组合。

重新组合阶段。在每个物体的编辑操作之后，我们进入重新组合阶段。在这一阶段，被删除或重新定位区域的潜层被重新初始化为高斯噪声，而被添加或修改的潜层则相应更新。对于有多个重叠物体的区域，我们先放置较大的掩码，以确保较小物体的可见性。

修改后的潜层堆栈经历最终前向扩散过程。该过程从一些步开始，其中未用高斯噪声重新初始化的区域被冻结（即被强制与同一步的未修改潜层对齐）。**这对于准确形成更新后的物体，同时保持背景一致性至关重要。**过程以若干步结束，在这些步中一切都可以变化，产生视觉上连贯且正确的图像。

算法 1：图像生成的自我修正

SLD 框架遵循标准文生图生成设置。给定用户提示词 P ，初始生成的图像 I ，最大自纠正轮数 K ，过程如下：对于第 k 轮，首先通过 LLM-Parser 解析提示词得到关键物体列表 S ，然后用检测器获取当前边界框 B_{curr} ，接着用 LLM-Analysis 分析当前图像与提示词的不一致得到目标边界框 B_{next} ，计算边界框差异得到编辑操作 Ops 。若 $Ops \neq \emptyset$ （即 $B_{\text{next}} \neq B_{\text{curr}}$ ），则执行修正操作生成新图像 I ；否则跳出循环。当 LLM 输出与输入相同的布局，或达到最大生成轮数时，过程终止。

4.3.4 自纠正过程的终止

虽然我们观察到在大多数情况下一轮生成通常已经足够，但后续轮次仍可能进一步提升正确性，使我们的自纠正成为一个迭代过程。确定最佳自纠正轮数对于平衡效率与准确性至关重要。我们设置了修正轮数的最大尝试次数。当 LLM 输出与输入相同的布局，或达到最大生成轮数时，过程终止。**这一迭代过程为图像正确性提供了保证——在**

检测器和 LLM 控制器的准确度范围内——确保其与初始文本提示词紧密对齐。

4.3.5 统一的文生图生成与图像编辑

除了自我纠正图像生成模型外，我们的 SLD 框架只需极少的修改即可适应图像编辑应用。一个关键区别在于用户输入提示词的格式：与用户只需提供场景描述的图像生成不同，**图像编辑要求用户同时详细说明原图像与期望的修改**。例如，要编辑一张有两个苹果和一根香蕉的图像，将香蕉替换为橙子，提示词可以是：“Replace the banana with an orange, while keeping the two apples unchanged.”

编辑过程与我们的自纠正机制类似：LLM 解析器从用户提示词中提取关键物体；开放词汇检测器随后识别这些物体；编辑导向 LLM 控制器分析这些输入，并提出更新后的边界框与对应的潜空间操作。

SLD 进行细致、物体级编辑的能力使其有别于现有的基于扩散的方法（如主要处理全局图像风格变化的 InstructPix2Pix）。同时，SLD 也超越了 DiffEdit 和 SDEdit 等工具，通过精确控制实现了全面的物体重新定位、添加和删除。

4.4 实验

4.4.1 与图像生成方法的对比

实验设置。我们在 LMD 基准上评测 SLD 框架的性能。对于每项任务，100 条程序化生成的提示词被输入到各种文生图生成方法中以产生相应图像。我们使用开放词汇检测器 OWL-ViT v2 评测方法与基线生成的图像。我们将 SLD 与多个领先的文生图扩散方法进行了对比，包括 Multidiffusion、BoxDiff、LayoutGPT、LMD+ 和 DALL-E 3。为确保公平比较，所有涉及 LLM 的模型均使用相同的 GPT-4 模型。对于 SLD 实现，我们使用 LMD+ 作为潜空间操作的基础模型，OWL-ViT v2 作为开放词汇物体检测器。

实验结果。如表 4.1 所示，将 SLD 方法应用于开源模型（LMD+）和商业模型（DALL-E 3）都能显著提升其生成正确性。对于否定任务，由于 LMD+ 将包含“without”信息的用户提示词转换为反向提示词，无需 SLD 集成即可达到 100% 准确率。相比之下，尽管 DALL-E 3 也使用 LLM 重写提示词，但在某些否定案例上仍然失败。**我们的 SLD 方法能自动修正大多数此类错误**。对于计数任务，将 SLD 与 LMD+ 集成带来了显著改进，准确率达 98%。DALL-E 3 在生成正确数量物体的图像方面常常吃力，而 SLD 实质性地缓解了这个问题，**性能提升超过 20%**。对于属性绑定任务，SLD 分别将 DALL-E

3 和 LMD+ 的性能提升了 6% 和 14%。对于空间推理任务，SLD 与 LMD+ 和 DALL-E 3 的集成分别展示了 12% 和 6% 的增强。

表 4.1: 我们的方法可应用于各种图像生成方法，并大幅提升生成准确率。

方法	否定	计数	属性绑定	空间关系	平均
Multidiffusion	29%	28%	26%	39%	30.5%
Backward Guidance	22%	37%	26%	67%	38.0%
BoxDiff	22%	30%	37%	71%	40.0%
LayoutGPT + GLIGEN	36%	65%	26%	78%	51.3%
DALL-E 3	25%	38%	74%	71%	52.0%
+ 1 轮 SLD (本文)	90%	61%	80%	83%	78.5% (+26.5)
LMD+	100%	82%	49%	86%	79.3%
+ 1 轮 SLD (本文)	100%	98%	63%	92%	88.3% (+9.0)

4.4.2 图像编辑应用

SLD 在现有方法上表现出出色的细粒度图像编辑能力。我们的整合使得局部潜空间区域内的精确修改成为可能。SLD 熟练执行特定编辑，如无缝地将苹果替换为南瓜，同时保留周围物体的完整性。相比之下，InstructPix2Pix 完全无法完成该任务，而 DiffEdit 常常无法精确定位待修改的物体。

SLD 支持多种编辑指令，包括：计数控制（如添加、删除或替换物体）、属性修改（如改变颜色或材质）、精细的位置控制（包含物体交换，大小调整和移动）。一个突出例子是 SLD 将桌上的杯子精确放大了 1.25 倍。这种精确性源于检测器的精确物体定位与 LLM 在推理和新位置建议方面的能力。这种对空间调整的精细控制在任何先前方法中都无可比拟。

4.4.3 多轮自纠正

表 4.2 的分析强调了多轮自纠正的好处，以及第一轮修正总是最有效的事实。第一轮修正大幅缓解了 Stable Diffusion 固有的问题。随后第二轮修正仍在所有四项任务上带来显著改进。

表 4.2: 虽然大多数错误通常在第一轮被修正，但多轮修正始终优于单轮方法。

方法	否定	计数	属性绑定	空间关系	平均
SD	19%	38%	24%	33%	28.5%
+ 1 轮 SLD	69%	55%	25%	69%	54.5% (+26.0)
+ 2 轮 SLD	73%	61%	31%	75%	60.0% (+31.5)

4.5 讨论

局限性。我们方法的局限性：SLD 难以精确移除人物的头发。尽管头发识别与定位成功了，但其复杂的形状对于区域选择的 SAM 模块构成了挑战，导致在移除头发的同时意外移除了人物的面部。由于人物的衣服没有被移除，基础扩散模型无法生成自然的组合。这表明需要更好的区域选择方法，以进一步提升生成与编辑质量。

4.6 小结

我们介绍了自纠正语言驱动 (Self-correcting Language-Driven, SLD) 框架，这是一个利用检测器和 LLM 进行自纠正的先驱性系统，显著增强了文本-图像对齐。该方法不仅在图像生成基准上设立了新的最先进水平 (SOTA)，而且与包括 DALL-E 3 在内的各种生成模型兼容。此外，SLD 还将其实用性扩展到图像编辑应用，提供了超越现有方法的细粒度物体级操控能力。

译注：本译稿已翻译原文”第 4 章 *Self-correcting LLM-controlled Diffusion Models*”全文 (4.1 引言 / 4.2 相关工作 / 4.3 方法 / 4.4 实验 / 4.5 小结)。后续章节 (第 5-9 章及附录) 仍待翻译，如需进一步翻译可分批进行。

5 Describe Anything: 精细的局部图像与视频字幕生成

本章基于以下已发表论文：

Long Lian, Yifan Ding, Yunhao Ge, Sifei Liu, Hanzi Mao, Boyi Li, Marco Pavone, Ming-Yu Liu, Trevor Darrell, Adam Yala, Yin Cui. “Describe Anything: Detailed Localized Image and Video Captioning.” *International Conference on Computer Vision (ICCV)*, 2025.

5.1 引言

图像字幕生成一直是计算机视觉与自然语言处理领域的长期挑战，因为它需要理解视觉内容并用自然语言进行描述。尽管最近的视觉-语言模型（VLMs）在图像级字幕生成方面取得了令人印象深刻的结果，为**图像内特定区域**生成详细且准确的字幕仍然是一个开放性问题。这一挑战在视频上更加复杂——模型还需额外捕捉动态视觉内容，如人物动作、物体运动以及人与物体的交互。如果得以解决，将为**细粒度锚定的图像/视频理解与生成**打开新的大门。

现有大多数 VLM（如 **GPT-4o**）缺乏精确的定位机制。近期让 VLM 接受二维定位线索（如边界框）的方法通常只能生成简短的短语，而非详细描述。虽然有一些方法能生成较长的字幕，但它们提供的细节有限或包含来自其他区域的不相关内容（如图 5.4 所示）。这便引出一个问题：**为什么精细的局部字幕生成（DLC, Detailed Localized Captioning）如此困难？**

我们识别出 DLC 的三个关键障碍：

1. **区域细节的丢失**：如图 5.1 所示，先前方法从全局图像表示中提取局部特征，往往会导致细粒度细节的丢失——特别是复杂场景中的小物体。当 LLM 处理这些视觉特征时，生成精确字幕所需的关键细节已经丢失。裁剪感兴趣区域可以增强细节，但会冒着丢失关键上下文线索的风险。
2. **高质量数据集的稀缺**：RefCOCO 和 Visual Genome 等数据集通常仅提供简短短语，不足以训练模型生成丰富、详细的字幕。近期的合成数据方法基于边界框，无法精确传达感兴趣区域；而依赖全局字幕的方法则可能难以捕捉非显著区域。
3. **基准测试的局限**：先前的局部字幕生成基准通常使用基于语言的图像字幕生成指

标或基于 LLM 的评分来比较生成字幕与参考字幕。然而，这些技术对 DLC 并不很适用。因为基准中的参考字幕往往缺乏该区域的全面细节，DLC 模型常因正确但参考未显式提及的细节而受到不公平的扣分。

我们针对这些挑战提出以下解决方案：

为应对区域特征中细节的丢失，我们提出 **Describe Anything Model (DAM)**，同时保留局部细节与全局上下文。DAM 通过两项关键创新实现这一点（图 5.2）：（1）**焦点提示词（focal prompt）**，以高令牌密度编码感兴趣区域；（2）**局部化视觉骨干网络（localized vision backbone）**，在整合全局上下文的同时保证精确定位。这些组件使 DAM 能够在复杂场景中对小物体生成详细且准确的字幕。

为克服高质量 DLC 数据集的稀缺性，我们引入**基于半监督学习（SSL）的数据流水线（DLC-SDP）**，分两阶段生成高质量局部字幕。首先，利用来自人工标注分割数据集的高质量掩码与关键词（如类别名、部件名或实体），我们查询一个 VLM，让它针对每个掩码所指区域，将每个关键词扩展为详细字幕。其次，受图像分类中基于自训练的 SSL 启发，DLC-SDP 以网络图像为未标注数据集、以分割数据集为标注数据，进行自训练。LLM 进一步将描述总结为多种粒度，产生一个具有高质量局部字幕的多样化数据集，使我们的模型能超越 GPT-4o 和 o1 等仅通过 API 调用的强基线。

为缓解现有基准的局限，我们引入 **DLC-Bench**，基于为每个区域预定义的正属性和负属性集合评估精细局部字幕，无需依赖完整的参考字幕。这种方法提供了更灵活、更准确的评估，鼓励模型生成信息丰富且精确的描述。

我们的贡献总结如下：

1. **Describe Anything Model (DAM)**：一种新型架构，通过焦点提示词和局部化视觉骨干网络实现多粒度的局部图像与视频字幕生成。
2. **SSL Data Pipeline (DLC-SDP)**：一种半监督数据流水线，利用高质量的分割标注和未标注网络图像，实现可扩展且多样化的数据策划。
3. **DLC-Bench**：一种专为评估 DLC 而设计的基准，无需参考字幕。

与通用模型不同，我们专注于跨多种粒度的局部图像与视频字幕生成，在 7 个覆盖关键词、短语和详细多句字幕生成的基准上达到 SOTA 性能。DAM、DLC-SDP 和

DLC-Bench 相对先前实践的优势列于表 5.1。我们的代码、模型、数据和基准已发布在 [describe-anything.github.io](https://github.com/describe-anything/describe-anything)。

表 5.1: 我们提出的 DAM 模型、SSL 数据流水线 DLC-SDP 和基准 DLC-Bench 相对先前实践的优势。

组件	先前实践	问题	我们的解决方案	优势
DAM	从全局图像特征提取区域特征	区域细节在图像特征提取阶段已经丢失，未提供给 LLM	为所提出的局部化视觉骨干网络提供焦点提示词	特征细节丰富且具有上下文，支持准确、多粒度的局部描述
DLC-SDP	用参照框和全局图像字幕查询数据策划 VLM	数据策划模型的参照不精确	将查询重新组织为基于掩码的关键词扩展问题	利用高质量、精确的人工标注区域掩码和关键词
DLC-SDP	全监督学习	数据有限且人工标注质量要求高	半监督学习	可扩展到多样化的网络规模未标注数据集
基准 (DLC-Bench)	预测字幕 + 参考标准字幕 → 基于语言相似性的指标或 LLM 评分器	对参考中未出现的正确细节产生不正确的幻觉惩罚	预测字幕 + 关于正/负属性的查询 → LLM 评分器	准确的细节和幻觉评估，无需依赖参考字幕

5.2 相关工作

视觉-语言模型 (VLMs)。 VLMs 整合视觉与文本输入进行多模态理解，可大致分为 BLIP 风格和 LLaVA 风格。然而，这些模型缺乏精确的定位能力，限制了其生成区域描述的能力。

局部化图像字幕生成。虽然通用 VLMs 能生成图像级字幕，但局部化字幕生成需要细粒度的区域描述。SoM 通过视觉标记增强 VLMs，但这些标记可能与背景融合。区域感知 VLMs 引入了局部参照输入。最近的工作如 Merlin、Artemis 和 VideoRefer 将基于区域的字幕生成扩展到视频。然而，这些方法仍然难以捕捉参照区域中的复杂细节（如图 5.4 所示）。这是因为先前模型要么从全局图像嵌入提取局部特征，要么只是简单地将参照条件编码为参照令牌，导致 LLM 所需的区域细节不足，尤其是对小物体。我们通过焦点提示词和局部化视觉骨干网络解决这一问题，平衡局部细节与全局上下文。

另一个限制是高质量数据集的稀缺。RefCOCO 和 VG 等数据集仅提供简短短语。最近的方法使用基于边界框的 VLM 查询（有时辅以全局字幕）进行合成生成，可能在区域特异性上引入问题。我们提出一种 SSL 数据流水线，使用人工标注和未标注数据生成更丰富的区域描述。

局部化字幕生成的基准测试。先前方法通过计算预测字幕与参考字幕之间的基于语言的图像字幕生成指标来评估局部化字幕生成。然而，这些指标侧重于文本匹配，可能与详细描述的事实正确性或质量相关性不佳。一些工作使用 Sentence-BERT 和纯文本 LLM 对预测相对于参考字幕打分。然而，参考字幕往往缺乏感兴趣区域的全面细节，会将模型正确但参考中未显式提及的细节当作幻觉进行惩罚。我们的 DLC-Bench 通过消除对参考字幕的依赖来解决这一问题。

具有聚焦能力的视觉模型。先前工作使用焦点自注意力、ToSA、ToMe、DW-ViT、Quadformer 和 V* 等方法增强对显著区域的注意力。这些方法根据模型定义动态分配资源到显著区域。相比之下，我们的焦点提示词显式优先考虑用户指定的区域，确保对非显著物体也能生成准确且详细的字幕。

5.3 Describe Anything Model (DAM)

Describe Anything Model (DAM) 生成用户指定区域在图像和视频内的详细局部描述。DAM 通过我们提出的焦点提示词和局部化视觉骨干网络，有效平衡局部细节与上下文信息。

5.3.1 任务形式化

精细局部字幕生成任务涉及生成专注于图像或视频内指定区域的综合文本描述。形式上，给定 N 个输入帧 $I^{(i)} \in \mathbb{R}^{H \times W \times 3}$ 及对应二值掩码 $M^{(i)} \in \{0, 1\}^{H \times W}$ （指示每帧中感

感兴趣的区域), 目标是通过字幕生成模型生成该区域内内容的详细描述 T :

$$T = \text{CaptioningModel}(\{I^{(i)}, M^{(i)}\}_{i=1}^N) \quad (10)$$

我们聚焦于使用二值掩码 $M^{(i)}$ 作为定位输入, 因为其他形式的定位 (如点、涂鸦、框或图像/视频子集的掩码) 可以通过分割模型 (如 SAM 和 SAM 2) 转换为掩码。为简洁起见, 我们首先介绍局部化图像字幕生成的方法, 省略帧索引 i , 然后在小节 5.3 扩展到视频。

5.3.2 模型架构

如图 5.2 所示, DAM 由两个关键组件组成: **焦点提示词**和**局部化视觉骨干网络**。

5.3.3 焦点提示词

为提供感兴趣区域在其上下文中的详细表示, 我们引入**焦点提示词 (focal prompt)**, 它同时包含完整图像和围绕指定区域的焦点裁剪图, 以及它们对应的掩码。

我们首先提取掩码 M 的边界框 B , 并在水平和垂直方向上以因子 α 扩展以包含更多周围上下文:

$$B' = \text{ExpandBox}(B, \alpha) \quad (11)$$

例如, 设置 $\alpha = 3$ 会得到一个最大可达原始边界框 9 倍大小的区域 (在图像边界处会被截断)。如果扩展框的高或宽小于 48 像素, 我们强制该维度的最小尺寸为 48 像素, 以确保对很小的区域也能提供充分的上下文。

图像和掩码的焦点裁剪如下:

$$I' = I|_{B'}, \quad M' = M|_{B'} \quad (12)$$

其中 $|_{B'}$ 表示按 B' 裁剪。因此, 焦点提示词由两部分组成: (1) 完整图像 I 及其掩码 M ; (2) 焦点裁剪 I' 及其掩码 M' 。通过同时包含完整图像和焦点裁剪 (连同它们的掩码), 焦点提示词既包含全局上下文, 又包含感兴趣区域的详细视图。

5.3.4 局部化视觉骨干网络

有效地用 VLM 处理焦点提示词的所有四个组件并非易事，因为简单地拼接完整图像和焦点裁剪会导致性能下降（表 5.8）。我们提出**局部化视觉骨干网络**，它（1）通过以空间对齐方式编码掩码实现局部化理解；（2）通过门控交叉注意力将全局上下文集成到感兴趣区域。

处理定位输入。类似于图像通过视觉 Transformer（ViT）中的线性补丁嵌入层编码，我们通过另一个以单通道 2D 输入的补丁嵌入层将掩码 M 集成到其对应的完整图像 I 中。

具体而言，完整图像 I 及其掩码 M 经过补丁嵌入层处理，然后通过**全局视觉编码器** $f_G(\cdot)$ 得到全局视觉特征 z 。焦点裁剪 I' 及其掩码 M' 经过类似过程，由**局部视觉编码器** $f_R(\cdot)$ 处理，不同的是 $f_R(\cdot)$ 还接受 z 作为上下文来获得最终的融合视觉特征 z' 。具体来说：

$$x = E_I(I) + E_M(M) + P, \quad z = f_G(x) \quad (13)$$

$$x' = E_I(I') + E_M(M') + P, \quad z' = f_R(x', z) \quad (14)$$

其中 $E_I(\cdot)$ 和 $E_M(\cdot)$ 分别是图像和掩码的补丁嵌入层， x 和 x' 是包含图像和掩码信息的全局和焦点嵌入输入， P 表示位置编码。

新增的掩码嵌入层 E_M 初始化为输出零，确保 VLM 在微调前的初始行为不受影响。

门控交叉注意力适配器的区域特征编码。为将全局上下文集成到焦点提示词中，我们在局部视觉编码器 f_R 的每个 Transformer 块中插入门控交叉注意力适配器。在自注意力和前馈层之后，我们添加一个门控交叉注意力机制，允许局部特征关注全局特征：

$$h'(l) = h(l) + \tanh(\gamma^{(l)}) \cdot \text{CrossAttn}(h(l), z) \quad (15)$$

$$h_{\text{Adapter}}^{(l)} = h'(l) + \tanh(\beta^{(l)}) \cdot \text{FFN}(h'(l)) \quad (16)$$

其中 $h(l)$ 是 f_R 中第 l 个自注意力块的输出， $\gamma^{(l)}$ 和 $\beta^{(l)}$ 是初始化为零的可学习缩放参数，CrossAttn 表示查询来自 $h(l)$ 、键和值来自全局特征 z 的交叉注意力，类似于编码器-解码器 Transformer 中使用的方式。 $h_{\text{Adapter}}^{(l)}$ 用于替换下一 Transformer 块中的 $h(l)$ 。为减少参数数量， f_R 与 f_G 共享自注意力块权重。

通过将 $\gamma^{(l)}$ 和 $\beta^{(l)}$ 初始化为零，我们确保模型的初始行为与原始 VLM 在微调前完全一致。在训练过程中，模型学会利用全局上下文来增强局部特征表示，从而促进生成详细

且上下文准确的描述。

5.3.5 生成详细的局部描述

来自全局和局部视觉编码器的视觉特征被组合并馈送到大型语言模型，以生成详细的、上下文感知的描述 T ：

$$T = \text{LLM}(t, z') \quad (17)$$

其中 t 表示文本提示令牌。

值得注意的是，所提出的组件并不增加视觉令牌的序列长度，确保 DAM 保持高效。通过将新增模块（掩码嵌入 E_M 与缩放参数 $\gamma^{(l)}$ 、 $\beta^{(l)}$ ）初始化为零，我们保留了 VLM 在微调前的预训练能力，允许对现成的 VLM 进行平滑适配而无需重新运行预训练。由于这种设计，我们的模型所需的训练数据（ $\sim 1.5\text{M}$ 样本）远少于涉及 VLM 预训练的先前工作。

5.3.6 扩展到视频

由于图像可视为单帧视频，模型通过处理帧序列及其对应掩码，自然扩展到处理视频。来自所有帧的视觉特征在序列维度上拼接并馈送到语言模型中，生成跨视频帧的详细局部描述，兼容 VLM 预训练时处理视频的方式。我们利用 SAM 2 将稀疏定位转换为每帧的掩码。

5.4 DLC-SDP：基于 SSL 的数据流水线

DAM 的有效性在很大程度上取决于用于详细局部描述的高质量训练数据的可用性。为此，我们提出基于半监督学习（SSL）的数据流水线（DLC-SDP），这是一个两阶段方法，使我们能够构建一个具有高质量局部描述的大型多样化数据集。

5.4.1 阶段一：利用已有标注

DLC-SDP 的第一阶段将数据生成问题重新组织为视觉锚定的描述扩展任务。我们观察到，尽管当前 VLMs 在给定参照掩码时往往难以生成详细局部描述，但它们能有效地将简短局部描述扩展为详细描述。受此观察启发，我们利用来自现有分割数据集的高质量人工标注掩码和关键词（物体类别名、部件名、实体等），将 VLM 查询重新组织为在给定参照掩码的情况下，将每个区域关键词扩展为详细字幕。

重要的是，我们的模型被训练为在不将初始关键词作为输入的情况下预测这些高质量描述。由于推理时不提供类别标签，且现有 VLMs 在没有类别标签时表现不佳，我们的方法确保了比直接通过 VLM 提示进行蒸馏更优的数据质量。

5.4.2 阶段二：使用未标注数据的 SSL

由于依赖高质量人工标注不可扩展，DLC-SDP 的第二阶段采用受图像分类中成功方法启发的、基于自训练的半监督学习技术。我们的自训练方法包含四个步骤：

1. **掩码生成**：我们使用开放词汇分割模型从未标注网络图像中提取物体掩码。
2. **描述生成**：我们的 DAM（最初基于标注分割数据集的 DLC 数据集进行训练）为这些区域生成详细局部描述。
3. **基于置信度的过滤**：我们应用基于 CLIP 的置信度过滤，仅保留高质量样本。
4. **数据扩展**：新生成的（图像、掩码、描述）三元组被加入我们的训练数据集。

这种半监督方法显著扩展了物体类别的范围，并增加了初始监督数据集之外的数据多样性。此外，为支持 DAM 的多粒度字幕生成能力，我们利用一个 LLM 将详细描述总结为更短的形式（如短语或短句），使 DAM 能灵活地生成从简洁短语到多句叙述的字幕。

通过系统地通过这种两阶段 SSL 流水线策划训练数据，DAM 取得了显著的性能改进。值得注意的是，使用 DLC-SDP 生成的数据训练的模型超越了 GPT-4o 和 o1 这两个强大的闭源基线，展示了 DLC-SDP 的有效性。

5.5 DLC-Bench: DLC 的基准

我们引入 **DLC-Bench**，一种专为 DLC 设计的基准，旨在消除对完整参考字幕的需求。**DLC-Bench** 的核心直觉是：理想的描述应在包含丰富相关细节的同时，严格避免事实错误或不相关区域的信息。因此，我们基于为每个区域预定义的正属性和负属性集合来评估预测。

如图 5.3 所示，针对像 DAM 这样的模型的评估过程有两个步骤：

1. 模型被提示为基准数据集中每个掩码区域生成详细描述。

2. 一个 LLM 作为裁判，通过回答关于区域细节的一组人工策划的正向和负向问题来评估生成的描述。

DLC-Bench 对每个标注实例使用两类问题：

- **正向问题**聚焦于应在描述中出现的物体部件的特定属性。如果描述准确包含指定细节，模型得分；遗漏不得分，而事实错误则扣分。
- **负向问题**聚焦于不应出现的细节——要么是相似物体典型但目标实例中不存在的属性，要么是与指定区域无关的描述。如果模型正确省略了这些细节，得分；反之，包含它们则扣分。为了避免完全不相关的字幕获得高分，只有当字幕正确识别物体时才能得分。

这种方法提供了更灵活、更准确的评估，鼓励模型生成信息丰富且精确的描述，不受不完整参考字幕的限制。

我们的 DLC-Bench 总共包含 892 个经过人工验证的问题，覆盖了广泛的属性和潜在的幻觉情况。

5.6 实验结果

DAM 在多种粒度的局部化图像和视频字幕生成上表现出色，包括关键词、短语和详细字幕，在 7 个域内和零样本基准上达到 SOTA（表 5.2 至 5.7）。我们在图像、视频和多视角精细局部字幕生成基准上进行了评估。

5.6.1 定量结果

开放类别关键词级局部字幕生成任务要求模型输出包含物体和部件实体的关键词来描述该区域。在物体级 LVIS 和部件级 PACO 数据集（表 5.2）上的测试中，我们的方法达到了最先进的性能。在 PACO 基准上，这是一个包含复杂场景中完整物体和部件并要求模型判断该区域是物体还是部件的具有挑战性的基准，我们的方法取得了 73.2% 的语义 IoU 和 84.2% 的语义相似度，相对先前最佳分别提升了 23.2% 和 8.5%。

短语级局部字幕生成任务要求模型为每个区域输出包含物体识别和属性的简短描述，通常在几个词之内。在 Flickr30k Entities 上进行的零样本测试中，我们的模型表现出色，相对先前最佳在 5 个指标的平均上取得了 12.3% 的相对改进。

详细局部字幕生成任务要求模型为每个区域输出详细描述，长度从长句到多句不等。理想描述包括区域中物体的描述、其部件以及它们的属性和关系。我们在具有挑战性的 Ref-L4 基准和我们提出的 DLC-Bench 上对该能力进行基准测试。在 Ref-L4 基准（表 5.4）上，我们的方法在短语言字幕生成指标上相对先前最佳取得了 33.4% 的平均相对改进，在长语言字幕生成指标上取得了 13.1% 的相对改进。

我们还在提出的 DLC-Bench 上对各种局部字幕生成模型进行了基准测试，DLC-Bench 不受先前基准需要参考字幕的限制。如表 5.5 所示，我们的 **Describe Anything Model (DAM)** 显著优于现有的通用和区域专用 VLMs，在正向和负向准确率上达到最先进的水平，展示了其生成详细且准确描述的能力。值得注意的是，**DAM 超越了 GPT-4o 和 o1 这两个强大的仅通过 API 调用的基线**。DAM 也超越了启用了思考模式的模型。

详细局部视频字幕生成要求模型为视频中每个区域输出详细描述。我们在具有挑战性的 HC-STVG 基准和 VideoRefer 提出的详细字幕生成基准上对该能力进行基准测试。在表 5.6 中，我们提出的 DAM 在 HC-STVG 上相对先前最佳取得了 19.8% 的相对改进，包括并行工作 VideoRefer。在表 5.7 中，即并行工作 VideoRefer 提出的基准上，我们提出的 DAM 在零样本和域内设置下均超越了先前最佳，其中零样本表示未在来自 Panda-70M 的域内数据集上进行训练，而该基准也从中获取视频。

最后，我们分析了 DAM 在 HD（幻觉检测）子任务上的性能，发现 DAM 经常预测参考字幕中未出现的正确细节。这表明该子任务上较低的零样本性能并不一定是由我们模型的幻觉引起的，而是由于参考字幕中缺失细节所致。这进一步说明了基于参考字幕评估的局限性。

5.6.2 定性结果

图 5.4 中的定性比较表明，DAM 在准确性和细节水平方面都表现出色。

详细局部视频字幕生成。DAM 能用任何一帧的定位描述视频中用户指定的对象。如图 5.5(a) 所示，DAM 能有效描述运动、遮挡等挑战性条件下的物体。

控制描述粒度。如图 5.6 所示，DAM 能通过不同提示词控制描述的细节量和长度。

零样本 3D 物体字幕生成。我们的模型还能描述 Co3Dv2 等多视角数据集中的物体，通过整合来自多个帧的信息来提供 3D 物体的一致描述（图 5.5(b)）。

5.6.3 消融研究

视觉提示策略。我们分析了不同的提示策略，发现**局部化输入和上下文信息对准确描述都至关重要**。仅使用完整图像限制了对特定区域的关注（48.7%），而局部裁剪改善了细节但丢失了上下文（60.1%）。简单拼接两者效果较差（42.4%）。添加交叉注意力显著提升了性能（63.2%），而使用焦点裁剪进一步改善了结果（65.4%）。**我们的最佳方法——焦点提示词，将焦点裁剪与交叉注意力相结合，无需增加 LLM 的序列长度即可达到 67.3% 的准确率。**

数据规模扩展。扩展监督数据集能提升性能，体现了多样化区域数据的价值。加入 10% 未标注 SA-1B 图像的半监督学习（SSL）将准确率进一步提升至 67.3%，展示了数据流水线的可扩展性。

我们还进行了额外的消融，包括在现有数据上以先前工作的架构训练模型、比较仅图像训练与图像-视频联合训练、以及消融提示词增强方法。

5.7 讨论与小结

我们引入了 DAM，一种用于图像和视频详细局部字幕生成的模型，通过焦点提示词和局部化视觉骨干网络平衡局部细节与全局上下文。我们开发了 DLC-SDP，一种利用分割数据集和未标注网络图像生成高质量字幕的 SSL 数据流水线。我们还提出了 DLC-Bench，一种使用基于属性的评估来克服基于参考评分的局限的基准。**DAM 在多粒度区域字幕生成的 7 个基准上达到了最先进的水平。**

译注：本译稿已翻译原文”第 5 章 *Describe Anything: Detailed Localized Image and Video Captioning*”全文（5.1 引言 / 5.2 相关工作 / 5.3 DAM / 5.4 DLC-SDP / 5.5 DLC-Bench / 5.6 结果 / 5.7 讨论与小结）。后续章节（第 6-9 章及附录）仍待翻译，如需进一步翻译可分批进行。

6 语言引导的视觉分解在当下仍具意义

6.1 为什么显式的视觉结构仍然重要

第 2 至 4 章的视觉生成方法是在一个特定时期开发的——那时，文生图与文生视频扩散模型虽然正在快速改进，但在面对组合型提示词时仍力不从心。自那以后，图像与视频生成器已大幅变强：它们往往能直接生成逼真的场景、遵循粗粒度的风格指示，并在没有显式布局接口的帮助下合成视觉上引人入胜的运动（在 LLM-grounded Diffusion、LLM-grounded Video Diffusion 或 Self-correcting LLM-controlled Diffusion 中均使用过显式布局）。

这种进展改变了这些方法的角色，但没有让它们所解决的根本问题变得过时。这些章节研究的核心问题并非“模型能否从文本生成一幅合理的图像或视频”，而是“生成过程能否可靠地满足用户指令的结构化约束：物体计数、空间关系、属性绑定、时序、以及用户指定的编辑”。现有的直接提示接口仍不能提供一种可靠的方式来保证这些约束在生成全过程中得到表示、保留并被检查。例如，提示词“六个排成 N 形的苹果”可能以视觉上细微但在语义上重要的方式失败：物体可能被调换、缺失、重复、颜色错误或被放置在错误的关系中。视频生成则增加了另一层难度——因为相同的实体和关系必须在时间上保持一致。

显式分解仍然有用，因为它把“应该生成什么”与“应该长什么样”分离开来。一个布局、场景图、边界框轨迹、掩码或修正计划，为系统提供了一种中间表示——可以被检视、编辑、验证和复用。即使现代生成器能直接满足许多提示词，**显式结构仍然为那些直接提示存在歧义或不可靠的案例提供了一种控制面**。这一点对于需要正确性而非仅仅美观的应用尤为关键：教学示意图、机器人仿真、空间推理数据、视觉编辑、合成训练数据以及多模态模型的评测套件。

图 6.1 的两个例子说明，这种困难在当下的生成器中并未消失：给定提示词“生成一张图：六个排成 N 形的苹果”，GPT-image-2 生成了看似合理的图像，但未能可靠地满足所请求的 N 形排列；而 Nano Banana 2 承认结果应当包含六个按 N 形排列的苹果，但生成了错误数量的苹果。这些例子表明，当前系统能识别出预期的约束，却仍无法在视觉输出中可靠地执行它们。

6.2 LMD、LVD 与 SLD 的持续价值

LLM-grounded Diffusion、LLM-grounded Video Diffusion 与 Self-correcting LLM-controlled Diffusion 应当作为更广泛的设计模式的实例来理解。它们使用语言模型不仅作为提示扩展器，更作为揭示视觉任务中潜在结构的规划器与控制器。LMD 提供了一种具体的方法，通过在合成之前将用户指令转化为显式空间布局，使图像生成更可靠；LVD 将同样思想扩展到视频，在时间维度上表示物体及其运动；SLD 增加了闭环验证与修正：在模型生成图像后，系统检查结果是否与指令一致，并在可能时修复失败。这些章节中使用的特定基础生成器可以被更新的模型取代，但每当生成器受益于外部规划、锚定或验证时，分解思想的相关性就依然成立。

这一视角与更强的端到端模型并不冲突。随着生成器不断改进，对于简单提示词，显式规划可能不再那么频繁地需要；但对于更困难的提示词、高风险用例以及交互式工作流而言，它变得更更有价值。用户可能希望锁定物体的位置、在改变属性的同时保留身份、指定时间维度上的运动，或仅修复图像中违反指令的部分。**这些是系统级需求，而非单纯的模型级能力。**分解思想提供了一种构造生成流水线的方法——其行为比单一的”提示直接到输出”调用更透明、更可控。

同样的论证也适用于评估。现代生成器可以使失败案例更难被发现，因为输出往往看起来很精致，即使它们在语义上是错误的。**显式的中间表示让询问”正确的实体是否出现？是否在正确的位置？时序关系是否保持？”变得更容易。**这使得第一部分的这些方法不仅作为生成技术具有意义，也作为分析与压力测试视觉生成器的工具而具有意义。

6.3 Describe Anything 为何仍然有用

Describe Anything 解决的是一个互补的问题：如何生成图像与视频中详细的局部描述。即使通用视觉-语言模型在不断改进，这一任务仍然有用，因为许多应用需要的描述要锚定在特定区域，而非整张图像。全局字幕可能说图像包含一个街景，但用户、数据集构建者或下游模型可能需要知道某辆选定的汽车、某个标志、某个人、某个工具或某个动作的细致外观、状态与上下文。

局部描述对数据生成很有价值。像 LMD 和 LVD 这样的系统需要关于物体、属性、空间关系以及时间行为的丰富监督。人工撰写的字幕很昂贵，且常常无法充分指定训练或评估可控生成所需的视觉细节。一个能详细描述选定区域的模型可以将现有图像与视频

转化为结构化的合成数据：物体级字幕、区域级属性、局部动作描述，以及基于真实视觉证据的空间关系示例。

这一任务在训练数据之外也有用。详细的局部描述可以支持面向视障人士的无障碍应用、交互式视觉搜索、内容审核、机器人、医学或科学标注工作流以及视觉编辑工具。在这些场景下，用户往往只关心场景中的某个局部，**需要一种在保留局部细节的同时不丢失全局上下文的描述**。Describe Anything 正是围绕这种张力设计的：它聚焦于选定的区域，却不抛弃赋予区域意义的周围场景。

因此，Describe Anything 不应仅被视为早期扩散系统的辅助数据生成器，它是一项具有持续独立实用价值的视觉理解任务。随着图像与视频生成系统变得更强大，局部字幕生成变得**更重要而非更不重要**：更强的生成器与编辑器需要更好的局部监督、更好的局部评估，以及更好的用户界面来指定他们关心的视觉场景部分。

6.4 第一部分回顾

贯穿第一部分的主线是：视觉智能受益于语言、视觉与生成之间的显式接口。LMD、LVD 与 SLD 展示了语言模型如何规划、控制并修正视觉合成；Describe Anything 展示了视觉-语言模型如何生成监督与评估这些系统所需的局部描述。具体模型与骨干网络将继续变化，但底下的这些疑问仍然贴近时代：系统应如何表示用户意图？该表示如何锚定于视觉结构？系统如何验证最终输出确实满足预期的关系？

当视觉生成器被部署到真实工作流中时，这些问题变得更加重要。当目标仅仅是产出一张吸引人的图像时，直接提示也许就足够了。当目标是产出一张**正确的图像、可控的视频、可编辑的场景、可靠的数据集，或可访问的视觉描述**时，分解仍然是一项实用的设计原则。

译注：本译稿已翻译原文”第 6 章 *Relevance of Language-Guided Visual Decomposition*”全文（6.1 为什么显式的视觉结构仍然重要 / 6.2 LMD、LVD 与 SLD 的持续价值 / 6.3 Describe Anything 为何仍然有用 / 6.4 第一部分回顾）。后续章节（第 7-9 章及附录）仍待翻译，如需进一步翻译可分批进行。